

**PENERAPAN METODE HISTOGRAM OF ORIENTED  
GRADIENT UNTUK EKSTRAKSI FITUR PADA SISTEM  
PENGENALAN PLAT NOMOR KENDARAAN**

**TUGAS AKHIR**

Diajukan sebagai syarat untuk menyelesaikan  
Program Studi Strata-1 Departemen Informatika

**Disusun Oleh:**

**Jeffry Saputra**

**1115040**



**PROGRAM STUDI INFORMATIKA  
INSTITUT TEKNOLOGI HARAPAN BANGSA  
BANDUNG  
2019**

## DAFTAR ISI

<b>LEMBAR PENGESAHAN</b>	<b>i</b>
<b>LEMBAR PERNYATAAN HASIL KARYA PRIBADI</b>	<b>i</b>
<b>ABSTRAK</b>	<b>i</b>
<b>ABSTRACT</b>	<b>i</b>
<b>PEDOMAN PENGGUNAAN TUGAS AKHIR</b>	<b>i</b>
<b>KATA PENGANTAR</b>	<b>i</b>
<b>DAFTAR ISI</b>	<b>iii</b>
<b>DAFTAR TABEL</b>	<b>iv</b>
<b>DAFTAR GAMBAR</b>	<b>v</b>
<b>I PENDAHULUAN</b>	<b>1-1</b>
1.1 Latar Belakang . . . . .	1-1
1.2 Rumusan Masalah . . . . .	1-2
1.3 Tujuan Penelitian . . . . .	1-2
1.4 Batasan Masalah . . . . .	1-3
1.5 Kontribusi Penelitian . . . . .	1-3
1.6 Metodologi Penelitian . . . . .	1-3
1.7 Sistematika Pembahasan . . . . .	1-4
<b>II LANDASAN TEORI</b>	<b>2-1</b>
2.1 Tinjauan Pustaka . . . . .	2-1
2.1.1 Citra Digital . . . . .	2-1
2.1.2 Pengolahan Citra . . . . .	2-1
2.1.3 Pengabuan Citra . . . . .	2-2
2.1.4 Deteksi Tepi . . . . .	2-2
2.1.5 <i>Hough Transform</i> . . . . .	2-3
2.1.6 Segmentasi . . . . .	2-5
2.1.7 Fitur pada Citra . . . . .	2-5
2.1.8 <i>Histogram of Oriented Gradient</i> . . . . .	2-5

2.1.9	<i>Support Vector Machine</i>	2-8
2.1.10	<i>Confusion Matrix</i>	2-11
2.1.11	Penggunaan <i>Library</i>	2-12
2.2	Tinjauan Studi	2-14
2.2.1	<i>State of the Art</i>	2-15
2.2.2	Pembahasan Penelitian Terkait	2-17
2.3	Tinjauan Objek	2-18
2.3.1	Tanda Nomor Kendaraan Bermotor	2-18
2.3.2	Jenis TNKB	2-20
2.3.3	<i>Dataset Tel-U Vehicle Data-set V1.0</i>	2-20
<b>III</b>	<b>ANALISIS DAN PERANCANGAN SISTEM</b>	<b>3-1</b>
3.1	Analisis Masalah	3-1
3.2	Kerangka Pemikiran	3-1
3.3	Urutan Proses Global	3-2
3.3.1	Proses <i>Training</i>	3-3
3.3.2	Proses <i>Testing</i>	3-4
3.4	Analisis Manual	3-5
3.4.1	<i>Dataset</i>	3-5
3.4.2	Tahap Pendeteksian Lokasi Plat Nomor	3-6
3.4.3	Tahapan Segmentasi Karakter	3-10
3.4.4	<i>Histogram of Oriented Gradient</i>	3-11
3.4.5	<i>Support Vector Machine</i>	3-16
<b>IV</b>	<b>IMPLEMENTASI DAN PENGUJIAN</b>	<b>4-1</b>
4.1	Lingkungan Implementasi	4-1
4.1.1	Spesifikasi Perangkat Keras	4-1
4.1.2	Lingkungan Perangkat Lunak	4-1
4.2	Implementasi Perangkat Lunak	4-1
4.2.1	Daftar <i>Class</i> dan <i>Method</i> Gradient	4-2
4.2.2	Daftar <i>Class</i> dan <i>Method</i> GradientCell	4-3
4.2.3	Daftar <i>Class</i> dan <i>Method</i> HOG	4-3
4.2.4	Daftar <i>Class</i> dan <i>Method</i> SVM	4-4
4.2.5	Daftar <i>Class</i> dan <i>Method</i> ConfusionMatrix	4-5
4.2.6	Tampilan Antarmuka Antar Aplikasi	4-6
4.3	Pengujian	4-9
4.3.1	Pengujian Kombinasi Parameter	4-9

<b>V PENUTUP</b>	<b>5-1</b>
5.1 Kesimpulan . . . . .	5-1
5.1.1 Saran . . . . .	5-2
<b>DAFTAR REFERENSI</b>	<b>vi</b>

## DAFTAR TABEL

2.1	Tabel fungsi <i>Library</i> OpenCV . . . . .	2-12
2.2	Tabel fungsi <i>Library</i> Weka . . . . .	2-13
2.3	Tabel fungsi <i>Library</i> JavaOCR . . . . .	2-14
2.4	<i>State of the Art</i> . . . . .	2-15
4.1	Daftar <i>Method Class Gradient</i> . . . . .	4-2
4.1	Daftar <i>Method Class Gradient</i> . . . . .	4-3
4.2	Daftar <i>Method Class GradientCell</i> . . . . .	4-3
4.3	Daftar <i>Method Class HOG</i> . . . . .	4-4
4.4	Daftar <i>Method Class SVM</i> . . . . .	4-5
4.5	Daftar <i>Method Class ConfusionMatrix</i> . . . . .	4-6
4.6	Hasil Pengujian dengan ukuran sel $2 \times 2$ piksel . . . . .	4-10
4.7	Hasil klasifikasi karakter dengan parameter CellSize = 2, NumBins = 4, dan Sigma = 0.01 . . . . .	4-11
4.7	Hasil klasifikasi karakter dengan parameter CellSize = 2, NumBins = 4, dan Sigma = 0.01 . . . . .	4-12
4.8	Hasil Pengujian dengan ukuran sel $4 \times 4$ piksel . . . . .	4-13
4.9	Hasil klasifikasi karakter dengan parameter CellSize = 4, NumBins = 9, dan Sigma = 0.01 . . . . .	4-14
4.9	Hasil klasifikasi karakter dengan parameter CellSize = 4, NumBins = 9, dan Sigma = 0.01 . . . . .	4-15
4.10	Hasil Pengujian dengan ukuran sel $8 \times 8$ piksel . . . . .	4-15
4.11	Hasil klasifikasi karakter dengan parameter CellSize = 8, NumBins = 18, dan Sigma = 0.1 . . . . .	4-16
4.11	Hasil klasifikasi karakter dengan parameter CellSize = 8, NumBins = 18, dan Sigma = 0.1 . . . . .	4-17
4.12	Hasil Pengujian dengan ukuran sel $16 \times 16$ piksel . . . . .	4-18
4.13	Hasil klasifikasi karakter dengan parameter CellSize = 16, NumBins = 9, dan Sigma = 1.0 . . . . .	4-19
4.13	Hasil klasifikasi karakter dengan parameter CellSize = 16, NumBins = 9, dan Sigma = 1.0 . . . . .	4-20

## DAFTAR GAMBAR

2.1	Contoh <i>Hyperplane</i> pada SVM [10]	2-9
2.2	<i>Confusion Matrix</i> untuk Dua Kelas [13]	2-11
2.3	Contoh dari plat nomor kendaraan Indonesia	2-19
2.4	Ilustrasi ukuran plat nomor untuk kendaraan roda empat Indonesia	2-19
2.5	Ilustrasi proses pengambilan citra <i>dataset</i>	2-21
3.1	Kerangka Pemikiran	3-2
3.2	<i>Flowchart Training</i> Sistem Pengenalan Plat Nomor Kendaraan	3-3
3.3	<i>Flowchart Testing</i> Sistem Deteksi dan Pengenalan Plat Nomor	3-4
3.4	Contoh citra karakter yang digunakan untuk tahap <i>training</i>	3-6
3.5	Skema Alur Pendeteksian Plat	3-6
3.6	Matriks Citra Asal berukuran $5 \times 5$	3-7
3.7	Matriks Citra Hasil <i>Grayscale</i>	3-7
3.8	Contoh Citra hasil deteksi tepi <i>Canny</i>	3-9
3.9	Ilustrasi matriks <i>Accumulator Space</i>	3-10
3.10	Contoh hasil keluaran dari tahapan segmentasi	3-11
3.11	Matriks citra hasil <i>preprocessing</i>	3-11
3.12	Matriks hasil Perhitungan Gradien sumbu X	3-12
3.13	Matriks hasil Perhitungan Gradien sumbu Y	3-12
3.14	Matriks hasil Perhitungan <i>Magnitude</i>	3-13
3.15	Matriks hasil Perhitungan Arah	3-13
3.16	Contoh hasil <i>Histogram of Oriented Gradient</i> untuk sel yang memiliki piksel dengan koordinat (2,5)	3-14
3.17	Matriks hasil Perhitungan Histogram untuk seluruh sel	3-14
3.18	Matriks hasil Normalisasi	3-15
4.1	Tampilan antarmuka aplikasi pengenalan plat nomor kendaraan	4-6
4.2	Tampilan antarmuka hasil <i>training</i>	4-7
4.3	Tampilan antarmuka hasil <i>testing</i> (Atas, tengah, bawah)	4-9

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

*Computer Vision* adalah sebuah cabang ilmu komputer yang mempelajari bagaimana komputer dapat memiliki kemampuan untuk dapat menginterpretasikan suatu kondisi melalui sebuah citra dan dapat bekerja selayaknya seperti penglihatan manusia. Terdapat beberapa tahapan dalam *computer vision* yang digunakan untuk persepsi visual, seperti akuisisi citra, pengolahan citra, formasi citra, ekstraksi dan pencocokan fitur, segmentasi, deteksi dan pengenalan objek, dan lain sebagainya. Deteksi objek adalah metode untuk mendeteksi suatu objek dan digunakan untuk mencari objek-objek dari suatu citra. Dalam aplikasi sistem kecerdasan untuk transportasi, objek dapat berupa mobil, bagian dari mobil (logo, plat nomor kendaraan), ataupun rambu-rambu lalu lintas.

Sistem kecerdasan untuk transportasi merupakan bidang yang saat ini sedang berkembang dengan pesat dalam ranah *computer vision* [1]. Penerapannya pun semakin nyata dalam kehidupan manusia sehari-hari. Sistem navigasi satelit, sistem pengenalan rambu lalu lintas, sistem parkir otomatis, pengenalan plat kendaraan, dan keamanan kendaraan merupakan contoh dari aplikasi sistem kecerdasan untuk transportasi. Pengenalan plat nomor kendaraan memegang beberapa peranan penting dalam bidang transportasi, diantaranya untuk sistem pembayaran elektronik, dan penegakan hukum [2].

Walaupun sistem pengenalan plat nomor kendaraan sudah memiliki sejarah penelitian yang panjang, hal ini tetap saja memiliki tantangan. Hal ini disebabkan banyak faktor yang mempengaruhi hasil akhir dari pengenalan plat nomor, contohnya adalah kondisi pencahayaan yang tidak merata, kondisi tulisan karakter pada plat nomor yang kurang jelas, dan lain sebagainya [2].

Secara umum, sistem pengenalan plat nomor kendaraan dibagi kedalam tiga bagian utama: deteksi area plat nomor kendaraan, segmentasi karakter, dan pengenalan karakter. Gou et al. menerapkan ketiga hal tersebut dengan menggunakan metode *Extremal Region* untuk mendeteksi lokasi plat nomor kendaraan sekaligus mendapatkan area dari karakter plat nomor kendaraan tersebut kemudian melakukan pengenalan karakter menggunakan *Restricted Boltzmann Machines* [3].

Penelitian lain menggunakan *Maximally Stable Extremal Region* untuk mendeteksi area karakter dari plat nomor kendaraan kemudian dilanjutkan dengan metode *Histogram of Oriented Gradient* untuk mendapatkan fitur dari masing-masing karakter dan menggunakan metode *Extreme Learning Machine* untuk melakukan proses pengenalan karakter [2].

Penelitian lain menggunakan metode morfologi citra untuk deteksi plat kendaraan dan menggunakan *K-Nearest Neighbors* untuk melakukan klasifikasi terhadap karakter dan *Support Vector Machine* untuk melakukan klasifikasi terhadap karakter yang memiliki kemiripan (pasangan B dengan 8, 5 dengan S, 4 dengan A, dsb) [1].

Penelitian lain menggunakan metode *Hough Transform* untuk mendeteksi lokasi plat kendaraan kemudian dilanjutkan dengan metode *Template Matching* untuk mengenali karakter dari plat nomor tersebut [4].

Penelitian ini menggunakan metode *Hough Transform* untuk mendeteksi plat nomor kendaraan, kemudian karakter-karakter pada plat kendaraan akan disegmentasi dengan menghitung grafik horizontal pita, kemudian dilanjutkan dengan menggunakan metode *Histogram of Oriented Gradient* untuk mengambil fitur dari karakter-karakter dari citra hasil segmentasi dan terakhir akan diklasifikasikan dengan menggunakan metode *Support Vector Machine*.

Pada tahapan pengujian akan dilakukan dua macam pengujian akurasi yaitu akurasi pengenalan plat kendaraan dan akurasi pengenalan karakter plat nomor kendaraan. Perhitungan akurasi akan menggunakan *confusion matrix*.

### 1.2 Rumusan Masalah

Berdasarkan latar belakang di atas rumusan masalah yang didapatkan adalah sebagai berikut:

1. Berapa akurasi pengenalan plat nomor kendaraan jika menggunakan metode *Histogram of Oriented Gradient* dan *Support Vector Machine* ?
2. Faktor apa saja yang dapat mempengaruhi hasil dari *Histogram of Oriented Gradient* dan *Support Vector Machine* ?

### 1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, tujuan penelitian Tugas Akhir ini adalah sebagai berikut:

1. Menerapkan metode *Histogram of Oriented Gradient* untuk ekstraksi fitur pada



karakter.

2. Menerapkan metode *Support Vector Machine* untuk klasifikasi karakter pada sistem pengenalan plat nomor kendaraan.
3. Menguji *HOG descriptor* dengan beragam ukuran sel dan jumlah *bin*.
4. Menguji akurasi pengenalan karakter pada plat nomor kendaraan dengan metode *Support Vector Machine* dengan beragam nilai sigma.

### 1.4 Batasan Masalah

Dalam penelitian ini, peneliti akan membatasi masalah yang akan diteliti antara lain:

1. Plat kendaraan yang akan dideteksi adalah plat nomor kendaraan Indonesia.
2. Citra plat kendaraan diambil dalam keadaan lurus dengan kamera. Tidak miring ke kiri dan juga miring ke kanan.
3. Plat kendaraan Indonesia yang akan dideteksi adalah plat nomor kendaraan pribadi (plat hitam dengan tulisan putih).

### 1.5 Kontribusi Penelitian

Kontribusi yang diberikan dari penelitian ini adalah:

1. Membuat penerapan metode *Histogram of Oriented Gradient* untuk proses ekstraksi fitur pada proses pengenalan karakter pada plat nomor kendaraan.
2. Menggabungkan metode *Histogram of Oriented Gradient* dengan *Support Vector Machine* untuk proses klasifikasi karakter.

### 1.6 Metodologi Penelitian

Metode penelitian yang dilakukan dalam penelitian ini adalah sebagai berikut:

#### 1. Studi Literatur

Penulisan ini dimulai dengan studi kepustakaan yaitu mengumpulkan bahan-bahan referensi baik dari buku, artikel, *paper*, jurnal, makalah mengenai sistem pengenalan plat nomor kendaraan.

#### 2. Data sampling

Data sampling yang akan digunakan berupa citra kendaraan yang berasal dari Universitas Telkom yang bernama *Tel-U Vehicle License Plate Data-set V1.0*. Dataset ini merupakan dataset yang disusun oleh akademisi Universitas Telkom untuk keperluan penelitian mengenai plat nomor kendaraan.

#### 3. Analisis Masalah

Pada tahap ini dilakukan analisis permasalahan yang ada, batasan yang dimiliki

dan kebutuhan yang diperlukan.

#### 4. Perancangan dan Implementasi Algoritme

Pada tahap ini dilakukan pendefinisian beberapa aturan dalam teknik *preprocessing* citra, serta perancangan pada algoritme yang akan dipakai untuk menyelesaikan masalah berdasarkan metode yang telah dipilih.

#### 5. Pengujian

Pada tahap ini dilakukan pengujian terhadap aplikasi yang telah dibangun.

#### 6. Dokumentasi

Pada tahap ini dilakukan pendokumentasian hasil analisis dan implementasi secara tertulis dalam bentuk laporan skripsi.

### 1.7 Sistematika Pembahasan

Pada penelitian ini peneliti menyusun berdasarkan sistematika penulisan sebagai berikut:

#### **BAB I        Pendahuluan**

Pendahuluan yang berisi latar belakang, rumusan masalah, tujuan penelitian, batasan masalah, kontribusi penelitian, serta metode penelitian.

#### **BAB II       Landasan Teori**

Landasan Teori yang berisi penjelasan dasar teori yang mendukung penelitian ini.

#### **BAB III      Analisis dan Perancangan**

Analisis dan Perancangan yang berisi analisis berupa algoritme yang digunakan.

#### **BAB IV      Implementasi dan Pengujian**

Implementasi dan Pengujian yang berisi implementasi pengujian dengan berbagai data testing beserta hasilnya.

#### **BAB V       Kesimpulan dan Saran**

Penutup yang berisi kesimpulan dari penelitian dan saran untuk penelitian lebih lanjut di masa mendatang.

## BAB II

### LANDASAN TEORI

Bab ini menjelaskan teori-teori yang berkaitan mengenai teori penunjang dan jurnal terkait yang digunakan dalam proses penelitian tugas akhir ini.

#### 2.1 Tinjauan Pustaka

Penelitian ini menggunakan beberapa teori terkait yang diperlukan dalam pengerjaan yang dilakukan. Penjelasan mengenai teori-teori tersebut akan dijelaskan sebagai berikut.

##### 2.1.1 Citra Digital

Citra digital merupakan sebuah fungsi dua dimensi  $f(x,y)$ , di mana  $x$  dan  $y$  adalah koordinat, dan nilai  $f$  menyatakan intensitas atau tingkat keabuan yang dimiliki citra pada titik atau *pixel* (*picture element*) tersebut. Nilai  $f$  merupakan nilai berhingga dan bersifat diskrit [5].

Jenis citra digital bergantung pada jenis perangkat keras yang digunakan dan dapat dikelompokkan ke dalam beberapa jenis model warna, yang paling umum digunakan adalah model RGB. Citra model RGB merupakan citra yang menggunakan 3 kombinasi warna, yaitu merah, hijau, dan biru. Pada citra RGB 24-bit, setiap warna mempunyai nilai  $f$  antara 0 hingga 255 sehingga perpaduan dari ketiga warna tersebut akan menghasilkan  $256^3$  jenis warna [5].

##### 2.1.2 Pengolahan Citra

Pengolahan citra dapat didefinisikan sebagai suatu bidang yang menggunakan citra sebagai masukan, lalu masukan tersebut diolah sehingga menghasilkan citra kembali. Berdasarkan definisi tersebut, perhitungan rata-rata dari suatu citra yang menghasilkan sebuah angka tidak termasuk pengolahan citra [5].

Terdapat satu paradigma yang mengkategorikan 3 jenis proses komputasi dalam pengolahan citra, yaitu tingkat rendah, tingkat sedang, dan tingkat tinggi. Proses tingkat rendah mencakup operasi yang sangat sederhana seperti *image preprocessing* untuk mengurangi *noise*, meningkatkan kontras, dan mempertajam citra. Proses tingkat sedang meliputi segmentasi untuk membagi daerah citra menjadi *region* atau objek. Sedangkan proses tingkat tinggi memungkinkan komputer untuk mengerti seperti pengenalan objek dan analisis citra [5].

### 2.1.3 Pengabuan Citra

Citra RGB yaitu citra berwarna memiliki ukuran yang lebih besar dibandingkan dengan citra *grayscale*. Untuk mempercepat proses komputasi pada citra, maka citra RGB perlu diubah menjadi citra *grayscale* dengan skala keabuan 256. Persamaan pengabuan citra dapat dilihat pada persamaan 2 . 1 dengan  $R$  melambangkan intensitas warna merah,  $G$  untuk intensitas warna hijau, dan  $B$  untuk intensitas warna biru.

$$Grayvalue = 0.299R + 0.587G + 0.114B \quad (2 . 1)$$

Persamaan 2 . 1 menyimpulkan bahwa persentase warna hijau yang paling besar karena manusia cenderung lebih sensitif terhadap perubahan warna hijau yang memiliki panjang gelombang sekitar 500-570 nm, merah, lalu biru [14], dan merupakan rekomendasi dari *International Telecommunication Union Radiocommunication Sector*.

### 2.1.4 Deteksi Tepi

Tepian memiliki arti yaitu terjadinya perubahan intensitas secara signifikan pada sebuah citra. Deteksi tepi ini digunakan untuk mendapatkan informasi bentuk dari citra masukan. Deteksi tepi yang digunakan pada penelitian ini adalah dengan menggunakan operator *Canny* untuk mendapatkan tepian citra sebesar 1 piksel. Proses deteksi tepi Canny memiliki tahapan sebagai berikut:

1. Penghalusan

Pada tahapan pertama citra dihaluskan dengan *Gaussian filter* untuk mengurangi derau yang dapat menghasilkan detail yang mengganggu.

2. Menghitung Gradien

Untuk menghitung gradien yang dapat menghasilkan tepian yang masih tebal dengan beberapa operator, diantaranya adalah Sobel, Prewitt, atau Robert.

3. *Non-maxima Supression*

Tahapan ini digunakan untuk menipiskan tepian tebal yang diperoleh dari operasi sebelumnya dengan cara mencari nilai maksimum di tepian.

4. *Double Thresholding*

Dari hasil *non-maxima supression* bisa ditemukan tepian yang belum

sempurna, sehingga perlu dilakukan *thresholding* untuk menghilangkan derau yang tidak diinginkan. Caranya adalah dengan menetapkan 2 nilai *threshold* yaitu *high threshold* dan *low threshold* untuk menentukan apakah piksel tersebut akan masuk dalam *threshold* untuk dijadikan tepian. Piksel yang nilainya berada di atas *high threshold* akan menjadi tepian kuat, sebaliknya jika di bawah *low threshold* akan dijadikan sebagai *background*.

### 5. Edge Tracking

Tahapan terakhir yaitu *Edge Tracking* atau *Edge Linking* digunakan untuk menghubungkan tepian kuat dan tepian lemah yang nilai pikselnya berada diantara *high threshold* dan *low threshold*. Ketika tepian lemah yang tidak terhubung dengan tepian kuat maka piksel tersebut akan dianggap sebagai *background*. Hasil akhir dari deteksi tepi Canny adalah tepian halus yang memiliki lebar sebesar 1 piksel.

### 2.1.5 Hough Transform

*Hough Transform* adalah sebuah teknik untuk mengidentifikasi bentuk spesifik dalam sebuah citra. *Hough Transform* mengkonversikan semua titik dalam sebuah kurva ke dalam sebuah lokasi tunggal dalam ruang parametrik (ruang akumulator) lain dengan transformasi koordinat. Metode ini bertujuan untuk memetakan fitur global ke fitur lokal. Konsep ini juga dapat diterapkan untuk mendeteksi garis lurus, lingkaran, elips atau bentuk geometrik lainnya. *Hough Transform* yang digunakan adalah untuk ekstraksi garis lurus. Berikut adalah rumus yang digunakan untuk mencari jarak antara titik *origin* dengan garis yang terbentuk [6]:

$$\rho = x \cos(\theta) + y \sin(\theta) \quad (2.2)$$

Dimana:

$\rho$  = jarak antara titik *origin* dengan garis

$x$  = koordinat titik  $x$

$y$  = koordinat titik  $y$

$\theta$  = sudut derajat;  $0^\circ \leq \theta \leq 180^\circ$

Metode *Hough Transform* menerapkan skema *voting*. Sebuah *array* akumulator diperlukan untuk menyimpan hasil *voting*. Rentang nilai  $\theta$  (*theta*) yang digunakan adalah antara nilai 0 hingga 180 derajat. Sedangkan rentang nilai  $\rho$  (*rho*) yang digunakan dalam akumulator adalah [7]:

## II. LANDASAN TEORI

---

$$-D \leq \rho \leq D \quad (2.3)$$

Dimana:

D = jarak diagonal dari citra

Karena citra yang digunakan berbentuk persegi panjang maka jarak diagonal memenuhi persamaan berikut [8]:

$$D = \sqrt{N^2 + M^2} \quad (2.4)$$

Dimana:

D = jarak diagonal dari citra

N = ukuran *width* dari citra

M = ukuran *height* dari citra

Sehingga rentang nilai *rho* yang digunakan dalam penelitian ini adalah:

$$-\sqrt{N^2 + M^2} \leq \rho \leq \sqrt{N^2 + M^2} \quad (2.5)$$

Dimana:

N = ukuran *width* dari citra

M = ukuran *height* dari citra

Setelah proses perhitungan *voting* dalam *accumulator space* selesai, yang dilakukan selanjutnya adalah memilih *peak* terbaik yang terdapat dalam *accumulator space*. Nilai *peak* yang tinggi memberikan indikasi yang baik dari garis [9]. Berdasarkan R. Varun, *et al.*, diketahui *local maxima* dari *accumulator space* dipertimbangkan sebagai *peak* yang menonjol. Jumlah *peak* merupakan hal yang krusial. Jumlah *peak* yang terlalu sedikit atau terlalu banyak dapat mempengaruhi kinerja sistem.

Algoritme pencarian *peak* menerapkan nilai *threshold* dan pencarian lokal yang berdasarkan dari ukuran *neighbourhood* (NS). Nilai *threshold* untuk membatasi nilai *voting* untuk mempertimbangkan *peak* yang menonjol. Nilai NS bernilai 1

atau lebih. Algoritme pencarian *peak* tersebut dapat menghindari hasil ganda untuk sebuah garis [9].

Serangkaian *peaks* yang diekstrak oleh metode *Hough Transform* akan menghasilkan beragam nilai *theta*. Intensitas kemunculan dari setiap nilai *theta* akan dihitung dan dijadikan fitur yang mewakili sebuah citra plat nomor.

Dari penjelasan di atas maka *output* dari proses ekstraksi fitur dengan metode *Hough Transform* adalah intensitas kemunculan dari setiap nilai *theta* yang didapat dari keseluruhan *peak* yang terpilih. Karena rentang nilai *theta* adalah 0 - 180 derajat maka ukuran fitur yang diekstrak adalah 181.

### 2.1.6 Segmentasi

Segmentasi merupakan proses pembagian daerah dalam suatu citra untuk dipisahkan ke dalam segmen-segmen tertentu. Tujuan utama dari proses segmentasi adalah menyederhanakan dan/atau mengubah representasi gambar menjadi sesuatu yang memiliki arti tertentu dan lebih mudah dianalisis. Segmentasi gambar secara umum digunakan untuk mengenali objek dan batas-batas (garis) dalam gambar.

### 2.1.7 Fitur pada Citra

Dalam sistem pengenalan objek, fitur merupakan hal yang penting. Fitur merupakan atribut yang menonjol atau karakteristik yang dapat membedakan antara satu objek dengan objek lainnya. Fitur pada sebuah citra dapat digunakan untuk proses segmentasi dan klasifikasi. Sebuah objek dapat dibedakan berdasarkan fitur internal dan fitur eksternal. Fitur internal didapatkan berdasarkan komposisi piksel yang membentuk suatu wilayah (*region*), sedangkan fitur eksternal membahas mengenai batas wilayah (*region boundary*) dari sebuah objek. Contoh fitur internal adalah fitur tekstur, fitur dasar geometri, momen, histogram, dan *Euler Number*. Fitur eksternal adalah *Chain codes*, *signatures*, dan *Fourier descriptors* untuk menggambarkan bentuk dari objek (*shape descriptor*) [5].

### 2.1.8 Histogram of Oriented Gradient

*Histogram of Oriented Gradients* merupakan salah satu teknik pengambilan fitur yang bertujuan untuk mengambil informasi penting dari sebuah citra. Cara kerja metode ini yaitu dengan mengevaluasi histogram lokal yang sudah ternormalisasi secara baik dari distribusi gradien citra dalam *grid* yang padat. Teknik mengekstrak fitur untuk metode ini yaitu dari distribusi lokal dari intensitas gradient tiap piksel yang terdapat pada sebuah objek citra. Dalam metode

## II. LANDASAN TEORI

---

*Histogram of Oriented Gradient*, ukuran sel berupa kumpulan atau gabungan piksel dan blok berupa kumpulan atau gabungan sel beserta jumlah *orientation bin* yang merupakan tempat untuk menampung hasil arah dan besar gradien akan mempengaruhi hasil keluaran fitur vektor yang dihasilkan dan juga akurasi yang didapat. Pertama untuk setiap piksel dari citra akan dihitung gradiennya dari sumbu x dan y dengan menggunakan persamaan :

$$G_x(x,y) = I(x+1,y) - I(x-1,y) \quad (2.6)$$

$$G_y(x,y) = I(x,y+1) - I(x,y-1) \quad (2.7)$$

Dimana:

$G_x(x,y)$  = nilai gradient untuk sumbu x

$G_y(x,y)$  = nilai gradient untuk sumbu y

$I(x,y)$  = nilai piksel citra dari baris x dan kolom y

Setelah didapat nilai gradient dari sumbu x dan y untuk setiap pikselnya, proses selanjutnya adalah menghitung besar nilai dan arah gradiennya dengan menggunakan rumus:

$$M(x,y) = \sqrt{G_x(x,y)^2 + G_y(x,y)^2} \quad (2.8)$$

$$\theta(x,y) = \arctan \frac{G_y(x,y)}{G_x(x,y)} \quad (2.9)$$

Dimana:

$M(x,y)$  = besar nilai gradient dari sumbu x dan y

$\theta(x,y)$  = arah nilai gradient dari sumbu x dan y

Kemudian, setiap piksel citra akan dibagi ke dalam beberapa sel yang dari setiap sel, akan dihitung persebaran *Histogram of Oriented Gradient*-nya melalui proses *voting*. Proses *voting* dalam *Histogram of Oriented Gradient* pertama akan menentukan nilai-nilai dari *bin* dengan membagi total jumlah sudut gradien ke dalam jumlah *orientation bin*. Kemudian untuk setiap arah sudut gradien dari



## II. LANDASAN TEORI

---

setiap piksel dalam sel akan dimasukkan ke dalam rentang *orientation bin* yang sudah ditentukan pada pertama kali, kemudian membagi besar nilai gradiennya dengan *orientation bin* yang terkait.

Setelah *Histogram of Oriented Gradient* sudah dibuat untuk setiap sel, proses selanjutnya adalah melakukan normalisasi terhadap hasil *vote* pada setiap *bin* dalam sel. Normalisasi akan dilakukan dalam 1 blok, dengan ukuran blok merupakan  $m \times n$  sel. Terdapat 4 macam metode untuk normalisasi, yaitu: *L2-Norm*, *L2-Hys*, *L1-sqrt*, dan *L1-Norm*. Persamaannya adalah sebagai berikut:

$$V_i = \frac{V_i}{\sum_{i=1}^N V_i} \quad (2.10)$$

Dimana:

$V_i$  = bobot vektor hasil *L1-Norm* yang merepresentasikan nilai setiap *bin*

$i$  = nilai *counter* dari 1 sampai N

$N$  = jumlah total nilai total *bin* yang digunakan dalam proses normalisasi

$$V_i = \sqrt{\frac{V_i}{\sum_{i=1}^N V_i}} \quad (2.11)$$

Dimana:

$V_i$  = bobot vektor hasil *L1-sqrt* yang merepresentasikan nilai setiap *bin*

$i$  = nilai *counter* dari 1 sampai N

$N$  = jumlah total nilai total *bin* yang digunakan dalam proses normalisasi

$$V_i = \frac{V_i}{\sqrt{\sum_{i=1}^N V_i^2}} \quad (2.12)$$

Dimana:

$V_i$  = bobot vektor hasil *L2-Norm* yang merepresentasikan nilai setiap *bin*

$i$  = nilai *counter* dari 1 sampai N

$N$  = jumlah total nilai total *bin* yang digunakan dalam proses normalisasi

Untuk algoritme rumus normalisasi *L2-Hys* merupakan algoritme mengikuti dari *L2-Norm*, namun dengan membatasi nilai maksimal hasil normalisasi sebesar 0,2.

## II. LANDASAN TEORI

---

Adapun proses normalisasi blok akan dilakukan dalam *sliding window* yang akan bergerak melakukan proses dengan pergeseran sebesar  $1 \times$  ukuran sel secara vertikal dan horizontal. Proses ini kemudian akan bersifat *overlapping* untuk beberapa sel yang dinormalisasi sehingga menimbulkan informasi yang redundan, namun akurasi yang dihasilkan justru semakin meningkat karenanya. Terakhir, hasil dari normalisasi tiap blok akan digabungkan menjadi 1 fitur vektor besar.


### 2.1.9 Support Vector Machine

*Support Vector Machine* merupakan salah satu algoritme *supervised learning* untuk melakukan klasifikasi serta regresi dengan menggunakan teori vektor. SVM dapat memetakan vektor input ke dalam sebuah ruang berukuran  $n$ -dimensional ( $n$  adalah jumlah fitur). Konsep dasar dari SVM adalah menemukan sebuah *separating hyperplane* (bidang) yang dapat memisahkan dua kelas dengan margin maksimal.

Garis putus-putus yang berada paling dekat dengan masing-masing kelas merupakan *hyperplane* paralel untuk memisahkan kedua kelas (lihat gambar 2.1). Asumsinya adalah semakin besar jarak atau margin antara 2 *hyperplane* pendukung ini maka semakin baik hasil klasifikasinya. *Hyperplane* yang optimal harus memenuhi persamaan 2 . 13 berikut:

$$w^T \cdot x + b = 0 \quad (2 . 13)$$

Dimana  $w^T$  adalah vektor berat dan  $x$  adalah vektor input dan  $b$  merupakan nilai bias. Tanda “.” menggambarkan perkalian dot vektor.



**Gambar 2.1** Contoh *Hyperplane* pada SVM [10]

SVM pada mulanya digunakan untuk menangani klasifikasi yang terdiri dari 2 kelas saja. Namun seiring dengan perkembangan zaman masalah yang dihadapi semakin kompleks sehingga membutuhkan teknik untuk melakukan proses klasifikasi lebih dari 2 kelas. Untuk melakukan klasifikasi lebih dari 2 kelas, terdapat 2 pendekatan yang bisa digunakan yaitu *One-Versus-One* dan *One-Versus-Rest*. Pada pendekatan *One-Versus-One*, akan dibuat sebanyak  $k(k-1)/2$  pasangan kelas untuk pengujian untuk klasifikasi dengan kelas sebanyak  $k$ . Untuk menentukan kelas mana yang menjadi klasifikasi untuk suatu kumpulan data caranya adalah sistem *voting*. Kelas dengan jumlah *voting* terbanyak akan menjadi *classifier* untuk data tersebut. Pada pendekatan *One-Versus-Rest* akan dibuat sebanyak  $k$  pasangan kelas untuk klasifikasi dengan kelas sebanyak  $k$ . Setiap kelas yang diuji akan dibandingkan dengan sisa kelas yang ada. Misal terdapat 3 kelas A, B, dan C, maka kelas A akan dibandingkan dengan kelas B dan C, kelas B dibandingkan dengan kelas A dan C, kelas C dibandingkan dengan kelas A dan B. Kekurangan dari pendekatan ini adalah jumlah *training set* yang tidak seimbang [10].

Untuk proses klasifikasi *non-linear* dapat dicari dengan persamaan 2.13 berikut:

## II. LANDASAN TEORI

---

$$f(x) = \text{sign}\left(\sum_{i=1}^l \alpha_i y_i K(x, x_i) + b\right) \quad (2.14)$$

Dimana:

- $\text{sign}(x)$  = Fungsi *signum*
- $l$  = Banyaknya kelas citra
- $\alpha_i$  = Nilai alpha ke  $i$
- $y_i$  = Nilai kelas citra ke  $i$
- $K(x, x_i)$  = Fungsi kernel
- $b$  = Nilai bias

Nilai  $\alpha$  dan  $b$  dapat dicari dengan persamaan linear yang membentuk *hyperplane* SVM. Persamaan 2.15 sampai 2.17 berikut merupakan persamaan *hyperplane* SVM:

$$\sum_{i=1}^l \alpha_i y_i K(x, x_i) + b = 0 \quad (2.15)$$

$$\sum_{i=1}^l \alpha_i y_i K(x, x_i) + b = 1 \quad (2.16)$$

$$\sum_{i=1}^l \alpha_i y_i K(x, x_i) + b = -1 \quad (2.17)$$

Dimana:

- $l$  = banyaknya kelas citra
- $\alpha_i$  = nilai alpha ke  $i$
- $y_i$  = nilai kelas citra ke  $i$
- $K(x, x_i)$  = fungsi kernel
- $b$  = nilai bias

Seringkali kasus yang ada dalam dunia nyata tidak selalu bisa dipisahkan secara linier (*linearly separable*) seperti pada contoh gambar di atas. Misalnya suatu kumpulan data memiliki fitur yang memiliki  $n$ -dimensi. Linear SVM tidak bisa diterapkan untuk kasus tersebut, sehingga diperlukan teknik agar membuat *hyperplane* yang bisa memisahkan antara 2 kelas dalam ruang multidimensi. Cara yang umum digunakan untuk menyelesaikan masalah tersebut adalah dengan menggunakan kernel. Kernel yang umum digunakan pada SVM yaitu *Radial Basis Function* seperti pada persamaan 2.18 berikut:

$$RBF = K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|}{2\sigma^2}\right) \quad (2.18)$$

Dimana:

- $K$  = nilai fungsi kernel RBF  
 $x_i$  = vektor input 1  
 $x_j$  = vektor input 2  
 $\sigma$  = konstanta sigma

### 2.1.10 Confusion Matrix

*Confusion Matrix* merupakan metode pengukuran untuk mengevaluasi hasil klasifikasi. Dengan melakukan klasifikasi sebanyak  $C$  kelas, dihasilkan *confusion matrix*  $M$  berukuran  $C \times C$ , di mana elemen  $M_{ij}$  dalam matriks menunjukkan jumlah sampel yang salah diklasifikasikan, sementara  $M_{ii}$  adalah jumlah sampel yang hasil klasifikasinya adalah benar. *Confusion matrix* pada gambar 2.2 digunakan pada kasus klasifikasi dua buah kelas sehingga membentuk matriks berukuran  $2 \times 2$  [13].

n=165		Predicted: NO	Predicted: YES	
Actual: NO		TN = 50	FP = 10	60
Actual: YES		FN = 5	TP = 100	105
		55	110	

**Gambar 2.2** *Confusion Matrix untuk Dua Kelas* [13]

Elemen  $M_{11}$  pada matriks menunjukkan jumlah sampel yang pada kenyataannya adalah kelas 1 dan diklasifikasikan sebagai kelas 1, sehingga disebut sampel *true-positive* (TP). Elemen  $M_{12}$  menunjukkan jumlah sampel yang pada kenyataannya adalah kelas 1 tetapi diklasifikasikan sebagai kelas -1, sehingga disebut sampel *false-negative* (FN). Elemen  $M_{21}$  menunjukkan jumlah sample yang pada kenyataannya adalah kelas -1 tetapi diklasifikasikan sebagai kelas 1, sehingga disebut sampel *false-positive* (FP). Dan elemen  $M_{22}$  menunjukkan jumlah sampel yang kenyataannya adalah kelas -1 dan diklasifikasikan sebagai kelas -1, sehingga disebut *true-negative* (TN). Maka untuk menghitung akurasi dapat digunakan persamaan 2.19. Hasil akurasi yang semakin baik akan mendekati

## II. LANDASAN TEORI

---

nilai 1, sebaliknya akurasi yang buruk mendekati nilai 0.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.19)$$

Lalu perhitungan *precision* yang merupakan perbandingan dari hasil positif dapat dihitung dengan persamaan 2.20.

$$Precision = \frac{TP}{TP + FP} \quad (2.20)$$

Dan perhitungan *recall* atau disebut juga sebagai sensitivitas dapat dihitung dengan persamaan 2.21.

$$Recall = \frac{TP}{TP + FN} \quad (2.21)$$

### 2.1.11 Penggunaan *Library*

Berikut adalah penjelasan dari *library* yang digunakan di dalam penelitian.

#### 2.1.11.1 OpenCV

*Library* yang digunakan adalah OpenCV untuk proses *pre-processing* citra. OpenCV merupakan *library open-source* yang banyak digunakan untuk penelitian terkait proses pengolahan citra dan *computer vision*.

**Tabel 2.1** Tabel fungsi *Library* OpenCV

No	Function	Deskripsi
1	Imgcodecs.imread(String filename)	Mengambil citra dari <i>path</i> yang diisikan ke parameter.
2	Imgproc.cvtColor(Mat src, Mat dst, int code)	Mengubah jenis warna pada citra sesuai yang diinginkan. Parameter fungsi ini terdiri dari Mat asal, Mat tujuan, dan <i>code</i> . <i>Code</i> digunakan untuk memilih tipe konversi citra tersebut, misal <i>grayscale</i> .

## II. LANDASAN TEORI

**Tabel 2.1** Tabel fungsi Library OpenCV (Lanjutan)

No	Function	Deskripsi
3	Imgproc.Canny(Mat image, Mat edges, double threshold1, double threshold2)	Fungsi ini digunakan untuk mendeteksi tepian pada citra menggunakan Canny.
4	Imgproc.GaussianBlur(Mat src, Mat dst, Size ksize, double sigmaX)	Melakukan <i>Gaussian Filter</i> terhadap citra yang dimasukkan ke dalam parameter dengan ukuran <i>kernel</i> dan nilai <i>sigma</i> yang diberikan.
5	Imgproc.threshold(Mat src, Mat dst, double thresh, double maxval, int type)	Melakukan <i>thresholding</i> terhadap seluruh nilai piksel dari citra yang dijadikan masukkan dengan nilai <i>threshold</i> , nilai maksimum, serta jenis metode <i>thresholding</i> yang digunakan, misalnya metode <i>thresholding</i> Otsu.
6	Imgproc.findContours(Mat image, List<MatOfPoint> contours, Mat hierarchy, int mode, int method)	Melakukan pencarian kontur terhadap citra yang dijadikan masukkan.
7	Imgproc.contourArea(Mat contour)	Melakukan perhitungan luas area dari kontur yang diberikan.
8	Imgproc.imwrite(String filename, Mat img)	Menyimpan citra yang diisikan ke parameter ke <i>path</i> yang dijadikan tujuan penyimpanan.

### 2.1.11.2 Weka

Weka adalah kumpulan dari algoritme pembelajaran mesin yang digunakan untuk menyelesaikan permasalahan *data mining*. *Library* ini berbasis bahasa pemrograman Java dan dapat berjalan di hampir seluruh platform. Dalam penelitian ini, *library* Weka digunakan untuk melakukan proses klasifikasi menggunakan metode *Support Vector Machine*.

**Tabel 2.2** Tabel fungsi Library Weka

No	Function	Deskripsi
1	libsvm.setOptions(String[] options)	Mengkonfigurasi dan menginisialisasi parameter dari <i>classifier</i> yang akan digunakan.
2	libsvm.buildClassifier(Instances insts)	Membangun <i>classifier</i> dari dataset yang diberikan sesuai dengan konfigurasi dan parameter yang digunakan.

## II. LANDASAN TEORI

---

**Tabel 2.2** Tabel fungsi Library OpenCV (Lanjutan)

No	Function	Deskripsi
3	libsvm.classifyInstance(Instance instance)	Melakukan prediksi kelas untuk data yang diberikan.

### 2.1.11.3 JavaOCR

JavaOCR adalah *library* berbasis Java untuk *Image Processing* dan *Character Recognition*. *Library* ini memiliki *GUI* sendiri dan dapat digunakan untuk pengembangan aplikasi *Character Recognition* pada perangkat Android dikarenakan *library* ini hanya membutuhkan *memory* yang sedikit dan tidak memiliki ketergantungan terhadap *library* lainnya.

**Tabel 2.3** Tabel fungsi Library JavaOCR

No	Function	Deskripsi
1	LineExtractor.slice(File inputImage, File outputDir)	Melakukan pencarian batas atas dan batas bawah area karakter dari citra masukan dan melakukan <i>cropping</i> terhadap citra tersebut dan kemudian hasil keluarannya akan berupa citra baru yang merupakan area karakter dari citra masukan, apabila terdapat lebih dari satu kandidat area karakter, maka hasilnya akan menjadi beberapa citra area karakter yang terpisah.
2	CharacterExtractor.slice(File inputImage, File outputDir, int width, int height)	Melakukan pencarian batas kiri dan batas kanan karakter dari citra masukan. Citra masukan berupa citra hasil keluaran dari <i>function</i> <i>LineExtractor.slice()</i> . Keluaran dari <i>function</i> ini akan berupa citra karakter yang didapatkan dari citra masukan, apabila terdapat lebih dari satu karakter, maka hasilnya akan menjadi beberapa citra karakter yang terpisah.

## 2.2 Tinjauan Studi

Pada bagian ini akan dijelaskan mengenai perbandingan dari berbagai penelitian terkait metode deteksi dan pengenalan plat nomor mobil.



### 2.2.1 *State of the Art*

Terdapat beberapa metode lain yang memiliki ruang lingkup yang mirip dengan penelitian ini khususnya mengenai deteksi dan pengenalan plat nomor mobil. Tabel 2.4 *State of the Art* akan menjelaskan perbedaan-perbedaan metode dari jurnal terkait.

**Tabel 2.4** *State of the Art*

<b>Jurnal</b>	<b>Rumusan Masalah</b>	<b>Metode</b>
Nugroho, A., Wardhani, K.R.R. (2011). Aplikasi Sistem Pembaca Plat Nomor Mobil Menggunakan Pengolahan Citra dan Metode Learning Vector Quantization.	Apakah dengan menerapkan pengolahan citra untuk deteksi plat kendaraan dan metode <i>Learning Vector Quantization</i> untuk pengenalan karakter dapat menghasilkan akurasi yang baik ?	<ol style="list-style-type: none"> <li>1. <i>Pengolahan Citra</i></li> <li>2. <i>Learning Vector Machine</i></li> </ol>
Gou, C., Wang, K., Yao, Y., Li, Z. (2016). Vehicle license plate recognition based on extremal regions and restricted Boltzmann machines. <i>IEEE Transactions on Intelligent Transportation Systems</i> , 17(4), 1096-1107.	Apakah dengan menerapkan pendeteksian plat nomor dengan <i>Extremal Region</i> dan pengenalan karakter plat nomor menggunakan <i>Hybrid Discriminative Restricted Boltzmann Machine</i> dapat meningkatkan akurasi pendeteksian dan pengenalan dalam berbagai kondisi cuaca dan <i>background</i> yang kompleks?	<ol style="list-style-type: none"> <li>1. <i>Extremal Region</i></li> <li>2. <i>AdaBoost</i></li> <li>3. <i>Histogram of Oriented Gradient</i></li> <li>4. <i>Hybrid Discriminative Restricted Boltzmann Machine</i></li> </ol>

**Tabel 2.4** *State of the Art* (Lanjutan)

Jurnal	Rumusan Masalah	Metode
Gou, C., Wang, K., Yu, Z., Xie, H. (2014, October). License plate recognition using MSER and HOG based on ELM. In <i>Proceedings of 2014 IEEE International Conference on Service Operations and Logistics, and Informatics</i> (pp. 217-221). IEEE.	Apakah dengan menerapkan <i>Maximally Stable Extremal Region</i> untuk pendeteksian plat nomor dan <i>Extreme Learning Machine</i> untuk pengenalan karakter plat nomor dapat meningkatkan performa dan akurasi sistem?	<ol style="list-style-type: none"> <li>1. <i>Maximally Stable Extremal Region</i></li> <li>2. <i>Histogram of Oriented Gradient</i></li> <li>3. <i>Extreme Learning Machine</i></li> </ol>
Tabrizi, S. S., Cavus, N. (2016). A hybrid KNN-SVM model for Iranian license plate recognition. <i>Procedia Computer Science</i> , 102, pp. 588-594.	Apakah dengan menggabungkan metode klasifikasi <i>K-Nearest Neighbours</i> dan <i>Support Vector Machine</i> akan menghasilkan akurasi yang lebih baik dan mengurangi <i>cost</i> pada proses pengenalan karakter plat nomor kendaraan?	<ol style="list-style-type: none"> <li>1. <i>Structural Feature</i></li> <li>2. <i>Horizontal and Vertical Crossing Count Histogram</i></li> <li>3. <i>Zoning Feature Extraction</i></li> <li>4. <i>K-Nearest Neighbours</i></li> <li>5. <i>Support Vector Machine</i></li> </ol>

**Tabel 2.4** *State of the Art* (Lanjutan)

Jurnal	Rumusan Masalah	Metode
Rasheed, S., Naeem, A., Ishaq, O. (2012, October). Automated number plate recognition using hough lines and template matching. In <i>Proceedings of the World Congress on Engineering and Computer Science</i> (Vol. 1, pp. 24-26).	Apakah dengan menggunakan metode <i>Hough Transform</i> untuk mendeteksi plat kendaraan dan <i>Template Matching</i> untuk pengenalan karakter dapat menghasilkan akurasi yang baik untuk sistem pengenalan plat nomor kendaraan?	<ol style="list-style-type: none"> <li>1. <i>Canny Detector</i></li> <li>2. <i>Hough Transform</i></li> <li>3. <i>Morphological Process</i></li> <li>4. <i>Template Matching</i></li> </ol>

### 2.2.2 Pembahasan Penelitian Terkait

Terdapat beberapa metode yang dapat khususnya untuk mendeteksi plat nomor dan mengenali karakter pada plat nomor. Pada referensi pertama [11] menggunakan metode pengolahan citra untuk mencari kandidat-kandidat pita dengan menghitung histogram gambar untuk mendapatkan lokasi plat nomor kendaraan, kemudian setiap karakter dari plat nomor yang didapatkan disegmentasi dengan cara menghitung grafik horizontal gambar, kemudian untuk metode klasifikasi karakter yang digunakan adalah *Learning Vector Quantization*.

Pada referensi kedua [3] menggunakan metode *Extremal Region* sebagai proses untuk mendapatkan daerah-daerah karakter dari suatu plat nomor, kemudian *Extremal Region* yang didapat diseleksi dengan menggunakan *AdaBoost* sehingga bisa didapatkan daerah karakter plat nomor yang sesuai dengan kriteria yang diinginkan, dari daerah-daerah karakter yang didapatkan barulah kandidat plat nomor yang benar bisa didapatkan. Proses selanjutnya adalah pengambilan fitur karakter dengan menggunakan metode *Histogram of Oriented Gradient* sehingga didapatkan fitur vektor dari setiap karakter pada plat nomor, yang nantinya akan menjadi masukan bagi metode klasifikasi *Hybrid Discriminative Restricted Boltzmann Machine*. Penelitian ini menghasilkan akurasi 98,2% untuk pengenalan karakternya.

Pada referensi ketiga [2] menggunakan metode *Maximally Stable Extremal Region* untuk memilih kandidat daerah karakter yang nantinya akan menentukan lokasi dari plat nomor berdasarkan letak geometris dari kandidat-kandidat karakter tersebut. Setelah lokasi plat nomor didapatkan, *HOG Descriptor* dari setiap

## II. LANDASAN TEORI

---

karakter diambil dengan menggunakan metode *Histogram of Oriented Gradient* dan setiap karakternya akan dikenali menggunakan metode *neural network* bernama *Extreme Learning Machine*. Penelitian ini menghasilkan akurasi 97,90 % untuk pengenalan karakternya.

Pada referensi keempat [1] digabungkan metode klasifikasi *K-Nearest Neighbours* dengan metode klasifikasi *Support Vector Machine*. *K-Nearest Neighbours* digunakan karena sifatnya yang mudah dipelajari, bersifat tangguh terhadap data yang memiliki derau dan efektif jika jumlah yang dimiliki berjumlah banyak. Sedangkan metode *Support Vector Machine* digunakan untuk karakter-karakter yang memiliki kemiripan karakteristik, sehingga akurasi dari pengenalan karakter dapat meningkat. Penelitian ini menghasilkan akurasi 97,03% untuk pengenalan karakternya.

Pada referensi kelima [4] menggunakan *Hough Transform* untuk mendeteksi lokasi plat kendaraan dan menghasilkan akurasi yang baik, yaitu sekitar 94% untuk plat nomor yang terdeteksi dan dengan menggunakan metode *Template Matching* menghasilkan akurasi pengenalan karakter plat nomor kendaraan sebesar 90%.

### **2.3 Tinjauan Objek**

Pada bagian ini akan diulas mengenai objek-objek yang terkait dengan deteksi dan pengenalan plat nomor kendaraan.

#### **2.3.1 Tanda Nomor Kendaraan Bermotor**

Tanda Nomor Kendaraan Bermotor (disingkat TNKB) disebut juga sebagai plat nomor atau nomor polisi adalah plat aluminium tanda kendaraan bermotor di Indonesia yang telah didaftarkan pada Kantor Bersama Samsat.

## II. LANDASAN TEORI


---



**Gambar 2.3** Contoh dari plat nomor kendaraan Indonesia

Plat nomor kendaraan Indonesia terdiri dari cetakan tulisan dua baris, pada baris pertama terdapat tiga hal yang diinformasikan, yaitu kode wilayah(huruf), nomor polisi(angka), dan kode/seri akhir wilayah(huruf). Sedangkan baris kedua menunjukkan bulan dan tahun masa berlaku, masing-masing dua digit. Contohnya pada gambar 2.3 angka yang terdapat di baris keduanya adalah 10.21. Hal tersebut menandakan bahwa plat nomor tersebut akan habis masa berlakunya pada bulan Oktober tahun 2021.

Bahan baku dari plat nomor adalah aluminium dengan ketebalan 1mm. Ukuran plat nomor untuk kendaraan bermotor roda dua dan roda tiga adalah  $250 \times 105$  mm, sedangkan untuk kendaraan bermotor roda empat atau lebih adalah  $395 \times 135$  mm. Terdapat cetakan garis lurus pembatas selebar 5mm di antara ruang nomor polisi dengan ruang angka masa berlaku (untuk plat nomor lama), sedangkan semenjak tahun 2011 di sekitar plat nomor terdapat garis putih dan tidak ada garis pemisah antara nomor polisi dan masa berlaku.



**Gambar 2.4** Ilustrasi ukuran plat nomor untuk kendaraan roda empat Indonesia

Berdasarkan gambar 2.4. Dengan ukuran panjang sebesar 395mm dan ukuran lebar sebesar 135mm. Maka dapat disimpulkan bahwa rasio untuk ukuran dari plat nomor Indonesia adalah 3:1 (panjang:lebar). Informasi dapat digunakan untuk proses pendeteksian plat kendaraan.

Pada tahun 2014 terjadi perubahan tampilan pada plat nomor untuk kendaraan bermotor roda empat. Plat nomor kini sedikit lebih panjang dari sebelumnya (5 cm lebih panjang) untuk memberi ruang pada kode/seri akhir wilayah yang dulunya berjumlah dua digit menjadi tiga digit.

### 2.3.2 Jenis TNKB

Jenis dari TNKB di Indonesia dibedakan berdasarkan warna dari TNKB tersebut, warna TNKB yang ditetapkan di Indonesia adalah sebagai berikut [12]:

1. Kendaraan pribadi dan sewa: warna dasar hitam dengan tulisan berwarna putih.
2. Kendaraan umum: warna dasar kuning dengan tulisan hitam.
3. Kendaraan milik pemerintah: warna dasar merah dengan tulisan berwarna putih.
4. Kendaraan bermotor sementara: warna dasar putih dengan tulisan berwarna merah.
5. Kendaraan korps diplomatik negara asing: warna dasar putih/merah dengan tulisan berwarna hitam.
6. Kendaraan staf operasional korps diplomatik negara asing: warna dasar hitam dengan tulisan berwarna putih serta terdiri dari lima angka dan kode angka negara yang dicetak lebih kecil dengan format sub-bagian.


### 2.3.3 *Dataset Tel-U Vehicle Data-set V1.0*

*Dataset Tel-U Vehicle Data-set V1.0* merupakan *dataset* untuk penelitian pendeteksian plat nomor kendaraan yang berasal dari Universitas Telkom. Universitas Telkom menyediakan *dataset* ini secara gratis dan dapat digunakan untuk umum.

Dalam *dataset* ini terdapat 228 citra kendaraan dengan plat nomor kendaraan yang diambil dari bagian depan kendaraan. Pengambilan citra dilakukan dari beragam posisi, sudut, jarak, dan pencahayaan.

## II. LANDASAN TEORI

---



**Gambar 2.5** Ilustrasi proses pengambilan citra *dataset*

Citra dalam *dataset* ini diambil dengan menggunakan kamera DSLR Canon EOS 500 D dan Canon EOS 550 D dengan resolusi 15 dan 18 megapiksel. Citra kemudian diubah resolusinya menjadi  $1024 \times 640$  piksel. Jenis plat nomor kendaraan yang ada di dalam *dataset* ini adalah plat kendaraan bermotor pribadi (plat hitam dengan karakter putih). Untuk penelitian ini, citra plat kendaraan yang akan digunakan adalah citra plat kendaraan bermotor yang diambil dengan posisi lurus dengan kendaraan dalam jarak kurang lebih satu meter dan kurang lebih 3 meter.

## BAB III

### ANALISIS DAN PERANCANGAN SISTEM

Bab ini memaparkan analisis masalah yang diatasi beserta pendekatan dan alur kerja dari perangkat lunak yang dikembangkan, mengimplementasikan metode yang digunakan dan hasil yang akan ditampilkan.

#### 3.1 Analisis Masalah

Pada bab 1 telah dijelaskan bahwa penelitian mengenai sistem pengenalan plat nomor kendaraan merupakan bidang yang masih berkembang dan implementasinya memegang peranan penting dalam bidang transportasi. Pada penelitian ini, metode yang akan digunakan adalah *Hough Transform* untuk mendeteksi lokasi plat kendaraan, kemudian menggunakan metode *Histogram of Oriented Gradient* untuk mengekstraksi fitur dari citra karakter dari plat nomor yang sudah disegmentasi dengan menghitung grafik horizontal pita, kemudian dilakukan klasifikasi dengan menggunakan metode *Support Vector Machine*.

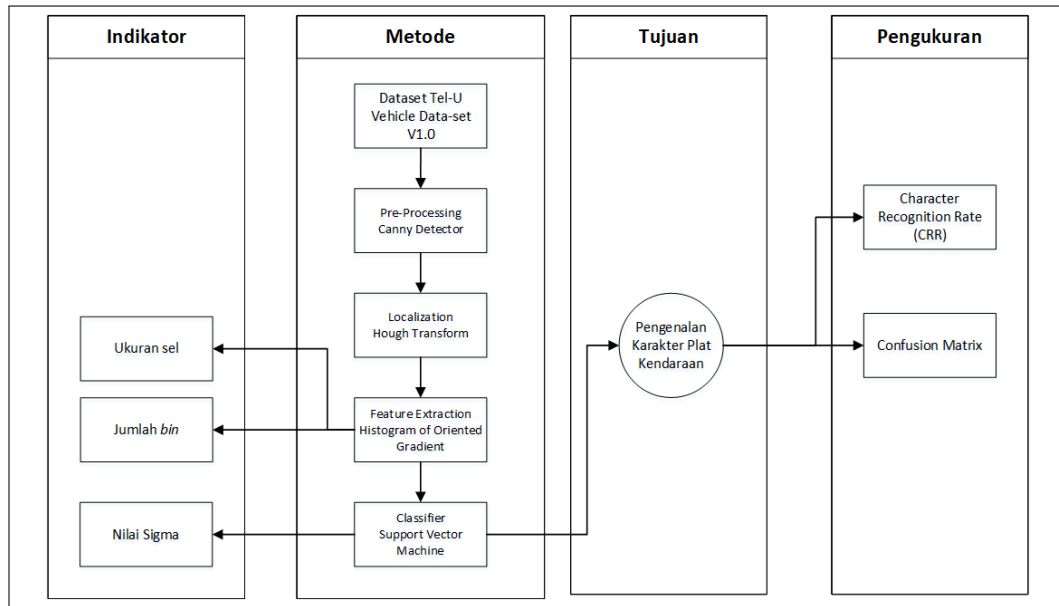
Masukan untuk sistem deteksi dan pengenalan plat nomor kendaraan ini adalah citra yang ditangkap oleh kamera DSLR Canon EOS 500 D dan Canon EOS 550 D beresolusi 15 dan 18 megapiksel. Citra tangkapan kemudian akan diubah resolusinya menjadi  $1024 \times 640$  piksel. Setiap citra masukan berisi bagian depan dari kendaraan yang memiliki plat nomor kendaraan.

Keluaran atau hasil dari sistem akan berupa teks hasil dari pengenalan karakter pada citra plat nomor kendaraan masukan.

#### 3.2 Kerangka Pemikiran

Berikut ini adalah kerangka pemikiran dari metode yang diusulkan untuk melakukan deteksi plat nomor kendaraan dan melakukan pengenalan karakter pada citra karakter yang terdapat pada plat nomor.






**Gambar 3.1** Kerangka Pemikiran

Seperti pada gambar 3.1, terdapat beberapa variabel indikator yang memengaruhi hasil dan perlu dilakukan penyesuaian, seperti ukuran sel pada metode *Histogram of Oriented Gradient*, jumlah *bin* yang menentukan batasan sudut yang digunakan, dan nilai sigma untuk *classifier Support Vector Machine*. Penelitian ini memiliki tujuan untuk menerapkan *Histogram of Oriented Gradient* dan *Support Vector Machine* untuk sistem pengenalan karakter pada plat nomor dengan menguji beragam faktor yang diduga akan mempengaruhi hasil akurasi dari penggabungan kedua metode tersebut. Hasil pengenalan karakter akan diukur dengan menggunakan *Confusion Matrix*.

### 3.3 Urutan Proses Global

Dalam sistem pengenalan plat nomor kendaraan terbagi atas dua proses yaitu proses *training* dan proses *testing*. Proses *training* dilakukan untuk mendapatkan kelas-kelas dari karakter-karakter yang akan dikenali. Proses *testing* dilakukan untuk menghitung hasil yang berupa akurasi dari pengenalan karakter pada plat nomor kendaraan.

#### 3.3.1 Proses Training




**Gambar 3.2** Flowchart Training Sistem Pengenalan Plat Nomor Kendaraan

Berikut ini adalah uraian dari *flowchart* pada gambar 3.2 yang dilakukan dalam penelitian ini:

1. Citra yang menjadi masukan adalah citra karakter hasil segmentasi dari citra plat nomor kendaraan. Citra karakter masukan berukuran  $32 \times 32$  piksel. Citra karakter berwarna hitam dengan latar belakang berwarna putih. Kumpulan karakter yang digunakan adalah karakter angka dari 0 sampai dengan 9 dan karakter huruf dari A sampai dengan Z, tidak ada karakter huruf kecil dikarenakan plat nomor kendaraan tidak ada yang menggunakan karakter huruf kecil.
2. *Histogram of Oriented Gradient* berfungsi untuk mendapatkan fitur dari citra masukan. Hasil dari ekstraksi fitur dengan menggunakan HOG adalah *HOG descriptor*, yang mendeskripsikan distribusi dari gradien berarah pada suatu area citra.
3. Ukuran sel dan blok yang digunakan untuk proses ekstraksi fitur dengan menggunakan *HOG* adalah beragam sesuai dengan ukuran-ukuran sel yang akan digunakan untuk proses testing dan jumlah *bin* yang digunakan juga akan beragam sesuai dengan ukuran *bin* yang digunakan untuk proses testing. Ukuran sudut yang akan dipakai adalah dari 0 sampai dengan 180 derajat.
4. *Support Vector Machine* (SVM) digunakan untuk mengklasifikasikan fitur-fitur yang sudah didapatkan ke dalam kelas-kelas dari karakter yang

akan dikenali. Metode *SVM* yang digunakan pada penelitian ini berasal dari *library WEKA*.

#### 3.3.2 Proses *Testing*



**Gambar 3.3** *Flowchart Testing* Sistem Deteksi dan Pengenalan Plat Nomor

Pada gambar 3.3 terlihat urutan proses *testing*. Pada proses *testing* terdapat beberapa proses yang sama seperti pada proses *training*. Berikut ini adalah uraian dari *flowchart* pada gambar 3.3 yang dilakukan dalam penelitian ini:


1. Citra pengujian yang digunakan didapatkan dari *dataset* plat nomor kendaraan Universitas Telkom yang bernama *Tel-U Vehicle Data-set V1.0*, penggunaan dari dataset ini sesuai dengan perizinan dari institusi yang bersangkutan.
2. Citra yang akan menjadi input dari *HOG* adalah citra hasil dari segmentasi karakter pada citra plat kendaraan hasil deteksi lokasi plat nomor kendaraan.
3. Ukuran dari sel dan blok yang digunakan untuk proses ekstraksi fitur dengan menggunakan *HOG* akan beragam sesuai dengan pengujian yang akan dilakukan.
4. Pada tahap *testing* model SVM yang digunakan berasal dari hasil keluaran model SVM pada tahap *training*.
5. Hasil keluaran akan berupa sebuah *string* yang menunjukkan kumpulan karakter yang berhasil dikenali oleh sistem.

#### 3.4 Analisis Manual

Pada bagian ini dilakukan analisis tahapan proses dengan melakukan perhitungan manual.

##### 3.4.1 Dataset

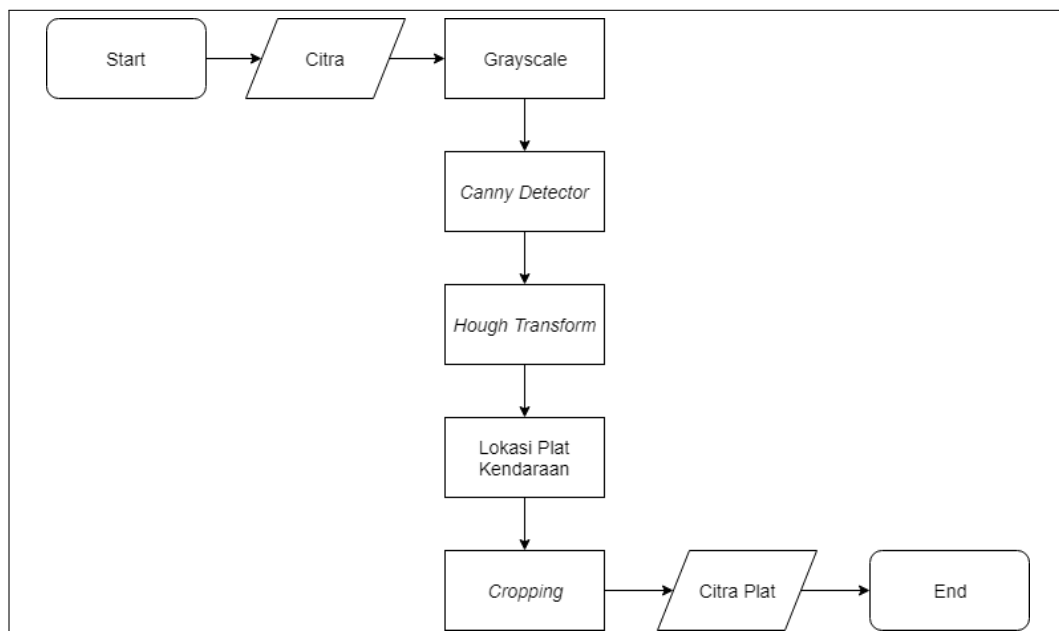
Untuk citra karakter yang akan digunakan pada tahap *training* akan digunakan citra karakter yang sudah disegmentasi dari citra plat kendaraan. Karakter terdiri dari angka 0 sampai dengan 9 dan karakter huruf kapital dari A sampai dengan Z. Untuk setiap karakter akan digunakan citra latih sebanyak tiga sampai dengan enam citra. Terlihat contoh citra karakter yang ditunjukkan pada gambar 3.4 merupakan contoh karakter angka dan huruf kapital yang akan dipakai. Dalam kumpulan citra karakter yang dijadikan *dataset*, tidak ada citra karakter tipis, karakter miring dan karakter huruf kecil. Tidak adanya jenis-jenis karakter tersebut dikarenakan pada plat nomor Indonesia, karakter yang digunakan hanyalah karakter huruf kapital dan angka dalam bentuk tegak dan tebal.



**Gambar 3.4** Contoh citra karakter yang digunakan untuk tahap *training*

#### 3.4.2 Tahap Pendeteksian Lokasi Plat Nomor

Skema alur dari tahap pendeteksian lokasi plat nomor adalah:



**Gambar 3.5** Skema Alur Pendeteksian Plat

##### 3.4.2.1 *Grayscale*

Proses pertama adalah mengubah citra masukan dari citra RGB menjadi citra *grayscale*, tujuan dari *grayscale* citra adalah untuk menghilangkan informasi warna dari setiap piksel citra. Untuk menghitung nilai derajat keabuan setiap piksel, diperoleh dengan menggunakan persamaan 2 . 1.

Di bawah merupakan contoh matriks citra asli dengan 3 *channel* warna yaitu *Red*, *Green*, dan *Blue* berukuran  $5 \times 5$  piksel.

### III. ANALISIS DAN PERANCANGAN SISTEM

R: 22 G: 26 B: 29	R: 24 G: 27 B: 32	R: 30 G: 33 B: 38	R: 32 G: 35 B: 42	R: 34 G: 39 B: 45
R: 25 G: 28 B: 33	R: 29 G: 32 B: 39	R: 32 G: 36 B: 45	R: 23 G: 27 B: 38	R: 23 G: 27 B: 39
R: 26 G: 30 B: 33	R: 29 G: 32 B: 37	R: 96 G: 103 B: 109	R: 124 G: 131 B: 139	R: 104 G: 109 B: 115
R: 26 G: 27 B: 31	R: 58 G: 59 B: 64	R: 103 G: 108 B: 112	R: 133 G: 138 B: 144	R: 155 G: 164 B: 169
R: 27 G: 28 B: 30	R: 41 G: 42 B: 46	R: 119 G: 124 B: 127	R: 108 G: 113 B: 119	R: 144 G: 153 B: 158

**Gambar 3.6** Matriks Citra Asal berukuran  $5 \times 5$

Dengan menggunakan persamaan 2.1, maka nilai matriks citra *grayscale* pada titik (3,3) akan menjadi sebagai berikut:

$$\begin{aligned}
 \text{Matriks}[3,3] &= (0.299 * 133) + (0.587 * 138) + (0.114 * 144) \\
 &= 137.189 \approx 137
 \end{aligned}$$

Perhitungan di atas dilakukan terhadap seluruh nilai matriks citra asal dan hasilnya adalah matriks citra berukuran  $5 \times 5$  dengan satu nilai derajat keabuan.

25	27	33	35	38
28	32	36	27	27
29	32	102	130	108
27	59	107	137	162
28	42	123	112	151

**Gambar 3.7** Matriks Citra Hasil *Grayscale*

#### 3.4.2.2 Deteksi Tepi Canny

Proses deteksi tepi dilakukan terhadap citra hasil *grayscale*. Pada penelitian ini, metode *Canny Edge Detection* digunakan untuk mendapatkan tepian. Berikut adalah algoritme dari metode *Canny Edge Detection* untuk mendapatkan tepian.

1. Citra masukan adalah citra dari hasil *grayscale* pada tahapan sebelumnya.
2. Citra masukan diperhalus dengan menggunakan *Gaussian Filter* untuk membuang derau.
3. Lakukan operasi perhitungan gradien menggunakan operator Sobel untuk mendapatkan tepian yang tebal.
4. Untuk menipiskan tepian yang didapat dari operasi sebelumnya maka teknik *Non-Maxima Suppression* dilakukan dengan mencari nilai maksimum pada tepian.
5. Buat 2 nilai *threshold* yaitu *high threshold* dan *low threshold* untuk menentukan piksel mana yang masuk dalam kategori tepian kuat, tepian lemah, dan bukan tepian. Jika nilai dari piksel tersebut di atas *high threshold*, maka piksel tersebut masuk ke dalam kategori tepian kuat, apabila nilai piksel berada di antara batas *high threshold* dan *low threshold*, maka piksel tersebut masuk ke dalam kategori tepian lemah, selebihnya akan masuk ke dalam kategori bukan tepian.
6. Tahapan terakhir adalah *Edge Linking* untuk menghubungkan tepian lemah dengan tepian kuat. Apabila piksel tepian lemah memiliki tetangga piksel (terhubung), maka piksel tersebut akan menjadi tepian.
7. Citra keluaran adalah citra biner yang merupakan hasil pendeteksian tepi.




**Gambar 3.8** Contoh Citra hasil deteksi tepi *Canny*

#### **3.4.2.3 Hough Transform**

Metode *Hough Transform* yang digunakan adalah untuk identifikasi garis lurus. Dalam ekstraksi fitur *Hough Transform* perlu menspesifikasikan *accumulator space* untuk menyimpan nilai *voting*. Spesifikasi *accumulator space* ditentukan berdasarkan ukuran citra input. Berikut adalah algoritme dari metode *Hough Transform* untuk mendapatkan garis lurus:

1. Citra masukan adalah citra biner hasil deteksi tepi pada tahapan sebelumnya.
2. Matriks *Accumulator Space* didefinisikan sebagai *array* 2 dimensi dengan sumbu horizontal menunjukkan nilai sudut ( $\theta$ ) yang digunakan dan sumbu vertikal adalah nilai-nilai dari  $\rho$ .





**Gambar 3.9** Ilustrasi matriks *Accumulator Space*

3. Untuk setiap nilai piksel dari citra biner hasil deteksi tepian, apabila nilai piksel tersebut adalah 0, piksel tersebut diabaikan. Jika nilai piksel tersebut tidak 0, maka lakukan perhitungan nilai  $\rho$  untuk piksel tersebut dan lakukan *voting* terhadap setiap nilai  $\theta$  yang digunakan dengan menambahkan nilai pada matriks akumulator dengan koordinat  $(\theta, \rho)$  sebesar satu.
4. Hasil dari perhitungan *voting* akan dicari hasil-hasil *voting* tertinggi untuk dijadikan kandidat garis melalui tahapan pencarian *Hough Peaks*. Tahapan ini dilakukan dengan menentukan nilai *threshold*, *neighbourhood*, dan jumlah *peaks* yang akan diambil.
5. Hasil pencarian *Hough Peaks* akan menghasilkan kumpulan nilai  $\rho$  dan  $\theta$ , nilai ini kemudian diubah menjadi koordinat titik.
6. Keluaran dari tahapan ini adalah *array* yang berisi pasangan koordinat titik dari kandidat-kandidat titik yang didapat.

#### 3.4.3 Tahapan Segmentasi Karakter

Setelah mendapatkan kandidat plat, maka berikutnya dilakukan segmentasi karakter untuk mendapatkan citra-citra karakter yang terdapat pada plat nomor kendaraan. Pada tahapan segmentasi karakter, akan dilakukan dua tahapan, yaitu segmentasi vertikal untuk mendapatkan batas atas dan batas bawah daerah karakter, dan segmentasi horizontal untuk mendapatkan batas kiri dan batas kanan untuk setiap karakter. Berikut adalah langkah-langkah dari proses segmentasi karakter:

1. Citra masukan adalah citra plat hasil tahapan deteksi plat kendaraan yang


### III. ANALISIS DAN PERANCANGAN SISTEM

---

sudah dilakukan *preprocessing* menjadi citra biner.

2. Lakukan segmentasi vertikal untuk mendapatkan batas atas dan batas bawah dari area kandidat karakter.
3. Lakukan segmentasi horizontal untuk mendapatkan batas kiri dan batas kanan dari setiap citra karakter.
4. Setiap citra karakter yang didapatkan akan di-*scaling* menjadi ukuran  $32 \times 32$  piksel. Hal ini bertujuan untuk menjaga konsistensi ukuran citra karakter yang digunakan untuk proses *training* dan proses *testing*.
5. Keluaran dari tahapan ini adalah citra-citra karakter yang terdapat pada plat nomor.

Pada penelitian ini, tahapan segmentasi karakter akan menggunakan *library* dari Java OCR dan *method* atau *function* yang digunakan dapat dilihat pada tabel 2.3.



**Gambar 3.10** Contoh hasil keluaran dari tahapan segmentasi

#### 3.4.4 *Histogram of Oriented Gradient*

Pada proses *Histogram of Oriented Gradients*, masukan untuk proses ini berupa citra yang berasal dari hasil segmentasi. Keluaran dari proses ini adalah matriks fitur vektor dari hasil perhitungan *Histogram of Oriented Gradients*. Berikut merupakan langkah-langkah untuk menghitung matriks fitur vektor. Pada gambar dapat dilihat hasil dari proses *resize* dan *crop* citra *grayscale* berukuran  $8 \times 4$  piksel.

89	92	88	92
90	88	90	86
91	90	90	94
91	122	91	122
89	90	89	91
90	85	90	86
91	90	92	93
91	122	91	120

**Gambar 3.11** Matriks citra hasil *preprocessing*

1. Proses pertama adalah untuk menghitung nilai gradien dari posisi vertikal dan horizontal untuk setiap piksel menggunakan persamaan 2 . 6 dan 2 . 7.

### III. ANALISIS DAN PERANCANGAN SISTEM

---

Contoh perhitungannya untuk piksel koordinat (2,5) dan hasil dari tahap ini dapat dilihat pada gambar 3.12 dan 3.13 di bawah:

$$G_x(2,5) = 89 - 89 = 0$$

$$G_y(2,5) = 85 - 122 = -37$$

0	-1	0	0
0	0	-2	0
0	-1	4	0
0	0	0	0
0	0	1	0
0	0	1	0
0	1	3	0
0	0	-2	0

**Gambar 3.12** Matriks hasil Perhitungan Gradien sumbu X

0	0	0	0
2	-2	2	2
1	34	1	36
-2	0	-1	-3
-1	-37	-1	-36
2	0	3	2
1	37	1	34
0	0	0	0

**Gambar 3.13** Matriks hasil Perhitungan Gradien sumbu Y

2. Untuk setiap piksel, hitung *magnitude* gradien dan arah gradien menggunakan persamaan 2 . 8 dan 2 . 9. Contoh perhitungannya untuk piksel koordinat (2,5) dan hasil dari tahap ini dapat dilihat pada gambar di bawah:

$$M(2,5) = \sqrt{0^2 + (-37)^2} = 37$$

$$\theta(2,5) = \arctan \frac{-37}{0} = 90$$

### III. ANALISIS DAN PERANCANGAN SISTEM

---

0	1	0	0
2	2	2	2
1	34	4	36
2	0	1	3
1	37	1	36
2	0	3	2
1	37	3	34
0	0	2	0

**Gambar 3.14** Matriks hasil Perhitungan *Magnitude*

90	0	90	90
90	90	45	90
90	89	14	90
90	90	90	90
90	90	45	90
90	90	71	90
90	88	18	90
90	90	0	90

**Gambar 3.15** Matriks hasil Perhitungan Arah

- Kemudian, tentukan ukuran sel, ukuran blok dan jumlah *oriented histogram bins*. Pada penelitian Dalas dan Triggs untuk mendeteksi pejalan kaki sebelumnya, didapat bahwa ukuran sel sebesar  $8 \times 8$  piksel, ukuran blok sebesar  $2 \times 2$  ukuran sel dan jumlah bin sebanyak 9 sudah dapat menghasilkan akurasi yang dapat mendeteksi pejalan kaki dengan cukup baik dibandingkan dengan ukuran-ukuran lainnya. Untuk contoh perhitungan analisis kali ini jumlah *oriented histogram bins* yang dipakai sebanyak 4 buah, sehingga didapat nilai sudut setiap *histogram bin* yaitu  $180 / 4 = 45$ . Untuk ukuran sel dipilih sebesar  $2 \times 2$  piksel dan ukuran blok sebesar  $2 \times 2$  sel.
- Kemudian untuk setiap sel, tentukan perhitungan *Histogram of Oriented Gradient* dengan melakukan *voting* dari arah gradien dan *magnitude* gradien, dimana arah gradien akan menjadi sudut *bin*, dan *magnitude* gradien akan menjadi bobot nilai. Berikut merupakan contoh proses *voting* untuk piksel dengan koordinat (2,5).


$$M(2,5) = 37$$

$$\theta(2,5) = 90$$

Sehingga untuk *bin* dengan sudut 90 akan mendapat nilai bobot sebesar 37 yang didapatkan dari nilai gradien *magnitude*-nya. Lakukan proses tersebut

### III. ANALISIS DAN PERANCANGAN SISTEM

untuk setiap sel sehingga masing-masing sel akan mempunyai *Histogram of Oriented Gradient*. Berikut contoh hasil perhitungan metode *Histogram of Oriented Gradient* pada sel yang terdapat koordinat piksel (2,5) dapat dilihat pada gambar 3.16.



**Gambar 3.16** Contoh hasil *Histogram of Oriented Gradient* untuk sel yang memiliki piksel dengan koordinat (2,5)

5. Kemudian untuk setiap blok, akan dilakukan normalisasi dengan menggabungkan hasil histogram dari setiap sel dalam bloknya. Adapun proses normalisasi dapat menggunakan 4 algoritme yaitu, *L1-Norm*, *L1-Sqrt*, *L2-Norm*, dan *L2-Hys*. Pada penelitian ini, penulis menggunakan algoritme normalisasi *L2-Norm* karena berdasarkan penelitian sebelumnya, hasil yang didapat lebih baik dari algoritme lainnya. Persamaan algoritme untuk proses normalisasi menggunakan *L2-Norm* didapat dengan menggunakan persamaan 2 . 12. Di bawah adalah contoh perhitungan normalisasi untuk blok pertama:

1	0	4	0	0	2	2	0
0	0.76	36.24	0	2.76	1.24	40	0
0	0	40	0	0	2.27	39.73	0
0	1.65	36.35	0	3.8	1.2	34	0

**Gambar 3.17** Matriks hasil Perhitungan Histogram untuk seluruh sel

Berdasarkan matriks pada gambar 3.17. Elemen matriks yang akan kita gunakan dalam perhitungan normalisasi ini adalah seluruh elemen baris

pertama dan baris kedua.

$$L2_{Norm} = \sqrt{1^2 + 0^2 + \dots + 2^2 + 0^2 + 0^2 + 0.76^2 + \dots + 40^2 + 0^2} = 54.29$$

Kemudian untuk setiap nilai dari histogram dari sel dalam blok tersebut akan dibagi dengan nilai hasil normalisasinya. Di bawah adalah contoh hasil normalisasi histogram dari sel pertama (matriks hasil perhitungan histogram baris pertama kolom 1-4):

$$\begin{bmatrix} 0.018418 & 0 & 0.07367 & 0 \end{bmatrix}$$

Lakukan proses normalisasi untuk setiap blok dengan menggeser secara horizontal sejauh 1 kali ukuran sel dan secara vertikal sejauh 1 kali ukuran sel sampai blok tersebut sudah berada di bawah kanan dari citra. Kemudian hasil dari proses normalisasi akan disusun menjadi matriks besar dengan jumlah kolom sebesar *jumlah bin × lebar blok dalam satuan sel × jumlah pergeseran horizontal* dan jumlah baris sebesar *jumlah pergeseran vertikal × tinggi blok dalam satuan sel*, dengan perhitungan tersebut, dalam analisa saat ini didapatkan ukuran matriks sebesar  $6 \times 8$ . Dalam analisa ini, hasil keluaran dari metode *Histogram of Oriented Gradient* ada sebanyak 48 fitur. Di bawah adalah hasil fitur vektor untuk metode *Histogram of Oriented Gradient* setelah melewati proses normalisasi.

0.0184	0	0.0736	0	0	0.0368	0.0368	0
0	0.0139	0.6674	0	0.0508	0.0228	0.7367	0
0	0.0097	0.4637	0	0.0353	0.0158	0.5118	0
0	0	0.5118	0	0	0.0290	0.5084	0
0	0	0.5307	0	0	0.0301	0.5271	0
0	0.0218	0.4823	0	0.0504	0.0159	0.4511	0

**Gambar 3.18** Matriks hasil Normalisasi

Setelah mendapatkan matriks *HOG descriptor* di atas. Langkah berikutnya adalah menjadikan matriks tersebut sebagai vektor. Hal ini dilakukan dengan mengambil setiap baris dari matriks dan memasukkannya ke dalam matriks vektor berukuran  $1 \times$  jumlah fitur. Vektor inilah yang akan dijadikan sebagai masukan bagi metode *Machine Learning* yang akan digunakan dalam penelitian ini.

#### **3.4.5 Support Vector Machine**

Tahapan terakhir dari sistem deteksi dan pengenalan plat nomor kendaraan adalah klasifikasi karakter. Tahapan ini bertujuan untuk mengklasifikasikan fitur-fitur dari *HOG descriptor* yang dihasilkan dari perhitungan metode *Histogram of Oriented Gradient* agar dapat dikenali sebagai karakter. *Support Vector Machine* yang akan digunakan dalam penelitian menggunakan *library* dari Weka SVM. Untuk *function* atau *method* yang digunakan pada *library* tersebut dapat dilihat pada tabel 2.2. *Support Vector Machine* termasuk dalam algoritme *supervised learning*. Konsep dasar dari metode ini adalah untuk menemukan sebuah *separating hyperplane* (bidang) yang dapat memisahkan dua kelas sebagai keputusan klasifikasi. Dalam penelitian ini karakter yang akan dikenali adalah huruf A sampai dengan Z dan angka dari 0 sampai dengan 9 sehingga akan terdapat 36 kelas untuk proses klasifikasi.

## **BAB IV**

### **IMPLEMENTASI DAN PENGUJIAN**

Pada bab ini akan menjelaskan mengenai proses implementasi dan pengujian terhadap sistem yang telah dibangun berdasarkan penjelasan pada bab sebelumnya.

#### **4.1 Lingkungan Implementasi**

Pada lingkungan implementasi, akan dijelaskan mengenai perangkat yang digunakan dalam proses pembangunan sistem baik dari perangkat keras maupun perangkat lunak yang digunakan.

##### **4.1.1 Spesifikasi Perangkat Keras**

Spesifikasi dari perangkat keras yang digunakan dalam pembangunan aplikasi adalah sebagai berikut:

1. *Laptop* ASUS A442UQ
2. *Processor* Intel Core i7-7500U CPU @ 2.7GHz
3. *Hard Disk* kapasitas 1TB
4. RAM 16GB

##### **4.1.2 Lingkungan Perangkat Lunak**

Spesifikasi dari perangkat lunak yang digunakan dalam pembangunan aplikasi adalah sebagai berikut:

1. Sistem Operasi Windows 10 Home 64 bit.
2. Netbeans IDE 8.2
3. Java Development Kit (JDK) 1.8.0\_161
4. *Library* OpenCV 3.4.6

#### **4.2 Implementasi Perangkat Lunak**

Pada bab ini akan dijelaskan mengenai implementasi aplikasi untuk pengenalan karakter pada citra plat kendaraan. Di bawah ini merupakan daftar *class* dan *method* beserta penjelasan mengenai cara kerja program.



#### IV. IMPLEMENTASI DAN PENGUJIAN

---

##### 4.2.1 Daftar *Class* dan *Method* Gradient

Berikut adalah tabel berisi *method* pada *class* Gradient. *Class* Gradient digunakan untuk menyimpan nilai *orientation* dan nilai *magnitude* dari suatu piksel citra.

**Tabel 4.1** Daftar *Method Class Gradient*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
1	Gradient	double orientation, double magnitude	void	Metode <i>constructor</i> yang digunakan untuk inisialisasi objek dari kelas Gradient dengan nilai <i>orientation</i> dan <i>magnitude</i> yang didapatkan dari perhitungan.
2	getOrientation()		double	Metode untuk mengembalikan nilai <i>orientation</i> dari suatu piksel.
3	getMagnitude()		double	Metode yang digunakan untuk mengembalikan nilai <i>magnitude</i> dari suatu piksel.
4	setOrientation()	double orientation	void	Metode untuk mengatur nilai <i>orientation</i> dari objek Gradient berdasarkan nilai <i>orientation</i> yang dijadikan masukan.

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.1** Daftar *Method Class Gradient*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
5	setMagnitude()	double magnitude	void	Metode yang digunakan untuk mengatur nilai <i>magnitude</i> dari objek Gradient berdasarkan nilai <i>magnitude</i> yang dijadikan masukan.

##### 4.2.2 Daftar *Class* dan *Method GradientCell*

Berikut adalah tabel berisi *method* pada *class GradientCell*. *Class GradientCell* digunakan untuk menyimpan nilai gradien dari setiap sel.

**Tabel 4.2** Daftar *Method Class GradientCell*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
1	GradientCell()	int length	void	Metode <i>constructor</i> yang digunakan untuk inisialisasi objek dari kelas GradientCell.
2	getGradients()		List <Gradient >	Metode untuk mengembalikan <i>List</i> dari gradien-gradien yang terdapat .

##### 4.2.3 Daftar *Class* dan *Method HOG*

Berikut adalah tabel berisi *method* pada *class HOG*. *Class HOG* digunakan untuk proses ekstraksi fitur dari citra karakter.

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.3** Daftar *Method Class HOG*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
1	HOG()	Integer[][] image, int cellHeight, int cellWidth, int blockSize, int numBins	void	Metode <i>constructor</i> yang digunakan untuk inisialisasi objek dari kelas HOG.
2	extractHOGFeatures()		double[]	Metode untuk mengekstraksi fitur <i>HOG descriptor</i> dari citra.
3	calculateGradientAndCells()		void	Metode yang digunakan untuk menghitung nilai gradien, <i>magnitude</i> , dan orientasi untuk setiap sel.
4	createHistograms()		void	Metode untuk membentuk histogram untuk mencatat persebaran arah dari setiap sel.
5	histogramNormalization()		void	Melakukan normalisasi <i>L2-Norm</i> untuk setiap elemen pada histogram.
6	createDescriptor()		void	Membentuk <i>HOG descriptor</i> dari hasil normalisasi histogram.

##### 4.2.4 Daftar *Class* dan *Method SVM*

Berikut adalah tabel berisi *method* pada *class SVM*. *Class SVM* digunakan untuk perhitungan klasifikasi.

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.4** Daftar *Method Class SVM*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
1	calculateRBFKernel()	double[][] data, double sigma, int classSource, int classTarget	double	Menghitung nilai RBF Kernel.
2	createRBFMatrix()	double[][] data, double[] sigma	double[][]	Membentuk matriks RBF dari data fitur.
3	createLinearEquation()	double[][] rbfMatrix, double[] classList	double[][]	Membuat persamaan linear dari matriks RBF.
4	getSolutions()	double[][] linearEquationMatix, double[] classList	Matrix	Mendapatkan solusi dari persamaan linear yaitu nilai alpha dan bias.
5	createRBFTestMatrix()	double[][] data, double sigma, double[] classList	double	Membentuk matriks RBF untuk data pengujian.
6	classify()	double[][] solutions, double[] rbfTest, double[] classList	double	Mendapatkan nilai hasil klasifikasi berdasarkan data uji dan nilai alpha dan bias.
7	getDataFromText()	String path	double[][]	Membaca matriks fitur dari file teks.

##### 4.2.5 Daftar *Class* dan *Method ConfusionMatrix*

Berikut adalah tabel berisi *method* pada *class ConfusionMatrix*. *Class ConfusionMatrix* digunakan untuk perhitungan akurasi dari hasil pengklasifikasian karakter yang dilakukan dengan metode SVM. *Confusion Matrix* juga biasanya digunakan sebagai alat ukur untuk menghitung kinerja dari algoritma klasifikasi yang digunakan.


#### IV. IMPLEMENTASI DAN PENGUJIAN

**Tabel 4.5** Daftar *Method Class ConfusionMatrix*

No	Nama <i>method</i>	Masukan	Keluaran	Keterangan
1	<code>getClassIndex()</code>	String label	int	Metode yang digunakan untuk mengembalikan nilai indeks <i>array</i> dari label yang dimasukkan.
2	<code>getConfusionMatrix()</code>	<code>int[][] result</code>	void	Metode untuk melakukan perhitungan <i>Confusion Matrix</i> dan juga menghitung akurasi dari hasil klasifikasi, metode ini juga akan menampilkan hasil <i>Confusion Matrix</i> sebagai keluaran pada antarmuka aplikasi.

##### 4.2.6 Tampilan Antarmuka Antar Aplikasi

Subbab ini akan menjelaskan tampilan antarmuka dari aplikasi pengenalan plat nomor kendaraan. Tampilan awal dari aplikasi ketika dibuka adalah seperti pada gambar 4.1.



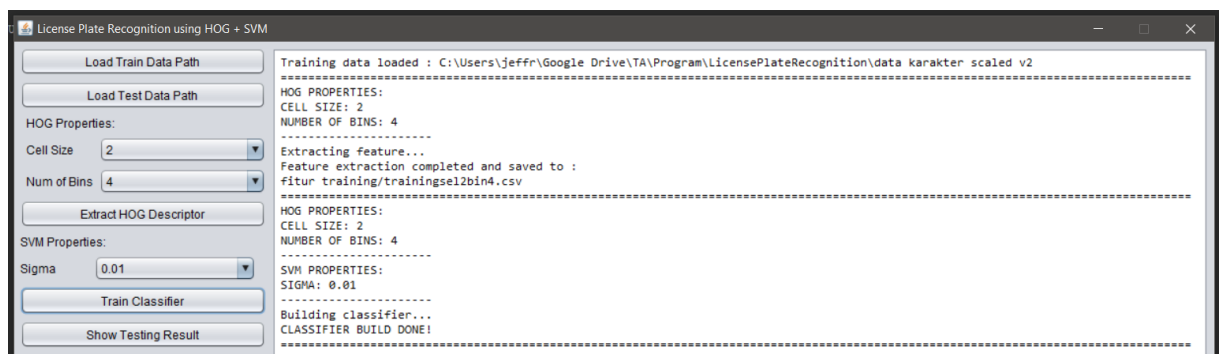
**Gambar 4.1** Tampilan antarmuka aplikasi pengenalan plat nomor kendaraan

Pada gambar 4.1, terdapat beberapa tombol diantaranya adalah tombol *Load Train Data Path*, *Load Test Data Path*, *Extract HOG Descriptor*, *Train Classifier*, dan

#### IV. IMPLEMENTASI DAN PENGUJIAN

*Show Testing Result.* Terdapat juga beberapa tombol *dropdown* yang berfungsi untuk memilih nilai dari parameter metode HOG dan SVM. Untuk metode HOG tombol *dropdown* yang tersedia adalah tombol *dropdown* untuk memilih ukuran sel (*Cell Size*) dan jumlah *bins* yang akan digunakan (*Num of Bins*). Sedangkan untuk metode SVM tombol *dropdown* yang tersedia adalah tombol *dropdown* untuk memilih nilai sigma yang akan digunakan. Tahapan proses pengenalan plat nomor kendaraan di aplikasi terbagi menjadi dua, yaitu proses *training* dan proses *testing*. Tahapan proses *training* pada aplikasi adalah sebagai berikut:

1. Memasukkan *path* dari kumpulan citra yang akan digunakan sebagai data latih untuk proses pengenalan karakter.
2. Memasukkan ukuran sel dan jumlah *bin* yang digunakan untuk metode HOG dengan memilih menggunakan tombol *dropdown Cell Size* dan tombol *dropdown Num of Bins*.
3. Klik tombol *Extract HOG Descriptor* untuk menjalankan proses ekstraksi fitur.
4. Klik tombol *Train Classifier* untuk menjalankan proses *training*.



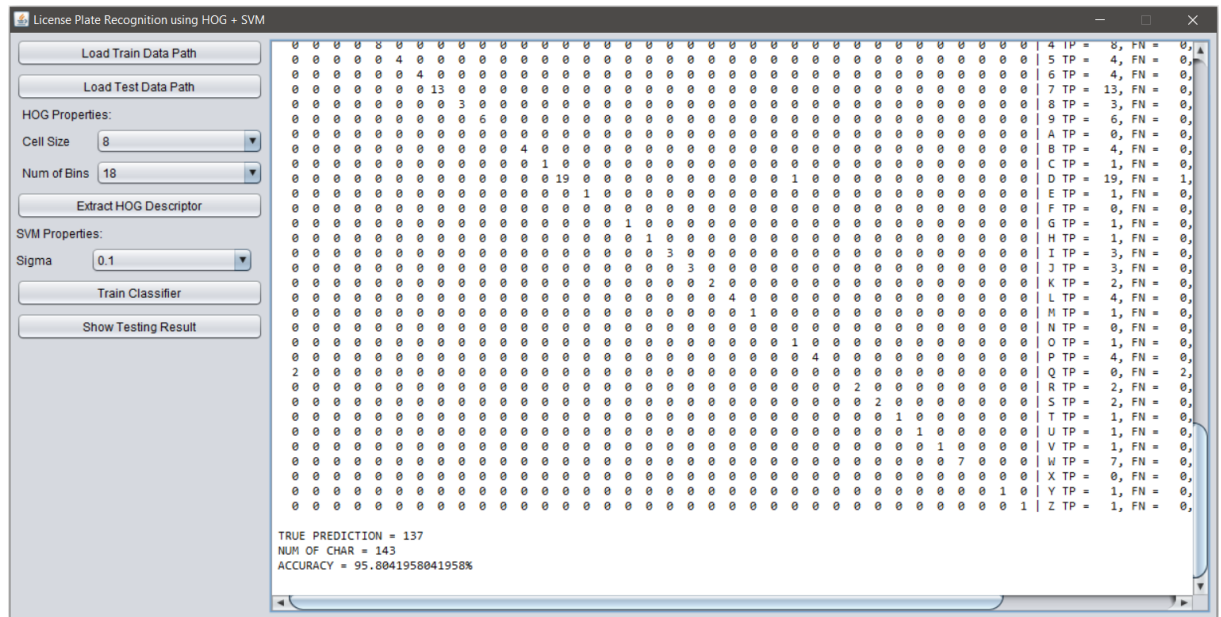
**Gambar 4.2** Tampilan antarmuka hasil *training*

Pada gambar 4.2 aplikasi akan menampilkan *path* dari folder citra yang akan digunakan sebagai data latih, ukuran sel dan jumlah *bins* yang digunakan untuk metode HOG, pesan bahwa proses ekstraksi fitur sudah berjalan dan lokasi penyimpanan fitur, dan pesan bahwa proses *training* sudah selesai. Sedangkan untuk tahapan proses *testing* pada aplikasi adalah sebagai berikut:

1. Lakukan proses *training* terlebih dahulu.
2. Setelah proses *training* selesai dilakukan, kemudian masukkan *path* dari folder citra yang akan digunakan sebagai data uji.
3. Klik tombol *Show Testing Result* untuk menjalankan proses testing otomatis.



## IV. IMPLEMENTASI DAN PENGUJIAN



**Gambar 4.3** Tampilan antarmuka hasil *testing* (Atas, tengah, bawah)

Pada gambar 4.3 aplikasi akan menampilkan *path* dari folder citra yang akan digunakan sebagai data uji, teks asli dari plat nomor pada citra beserta hasil prediksi dari SVM, jumlah plat yang teridentifikasi dengan benar, jumlah total plat yang diproses, akurasi plat yang terdeteksi dan teridentifikasi dengan benar, hasil dari *confusion matrix* untuk klasifikasi karakter, jumlah karakter yang terklasifikasi dengan benar, jumlah keseluruhan karakter, dan akurasi dari klasifikasi karakter.

### 4.3 Pengujian

Pada bagian ini, akan dilakukan berbagai skenario pengujian dengan beragam parameter dari metode HOG. Tujuan dari penelitian ini adalah untuk menerapkan metode HOG pada proses ekstraksi fitur karakter pada sistem pengenalan karakter, oleh karena itu perlu diketahui berapa ukuran sel, ukuran blok, dan jumlah *bin* yang akan menghasilkan fitur yang paling baik untuk akurasi pengenalan karakter. Pengujian ini akan dilakukan dengan data latih sebanyak 117 citra karakter hasil segmentasi dari plat nomor untuk 36 kelas karakter yang terdiri dari 10 kelas angka dan 26 kelas huruf, dimana setiap kelas karakter memiliki jumlah data latih sebanyak 3-5 citra.

#### 4.3.1 Pengujian Kombinasi Parameter

Pada bagian ini akan dilakukan pengujian untuk beragam kombinasi parameter dari metode HOG dalam mengekstraksi fitur karakter. Fitur dari metode *HOG* akan digunakan pada proses klasifikasi karakter menggunakan *library* dari Weka dan akan diukur akurasinya menggunakan *Confusion Matrix*. Adapun nilai dari



#### IV. IMPLEMENTASI DAN PENGUJIAN

setiap parameter yang akan digunakan untuk kombinasi, yaitu:

1. Ukuran sel yang akan digunakan : 2, 4, 8, 16
2. Ukuran blok yang akan digunakan : 4, 8, 16, 32
3. Jumlah *bin* yang akan digunakan : 4, 6, 9, 18

Adapun untuk nilai sigma pada metode *SVM* yang digunakan dalam kombinasi adalah 0.01, 0.1, dan 1.

##### 4.3.1.1 Pengujian dengan Ukuran Sel 2

Pada bagian ini, pengujian akan dilakukan dengan menggunakan ukuran sel berukuran  $2 \times 2$  piksel dan ukuran blok  $2 \times 2$  sel ( $4 \times 4$  piksel). Jumlah bin yang akan digunakan adalah 4, 6, 9, dan 18. Sedangkan untuk nilai sigma pada metode *SVM* yang akan digunakan adalah 0.01, 0.1, dan 1. Berikut adalah hasil pengujian untuk setiap kombinasi parameter tersebut:

**Tabel 4.6** Hasil Pengujian dengan ukuran sel  $2 \times 2$  piksel

Parameter			CRR	OVR
CellSize	NumBins	Sigma		
2	4	0.01	61.53%	14.28%
2	4	0.1	28.67%	0%
2	4	1	20.27%	0%
2	6	0.01	53.84%	9.52%
2	6	0.1	27.97%	0%
2	6	1	20.27%	0%
2	9	0.01	52.44%	4.76%
2	9	0.1	27.27%	0%
2	9	1	20.27%	0%
2	18	0.01	48.25%	4.76%
2	18	0.1	27.97%	0%
2	18	1	20.27%	0%

Berdasarkan tabel di atas, dapat disimpulkan bahwa akurasi pengenalan karakter maksimal yang didapatkan apabila menggunakan ukuran sel  $2 \times 2$  piksel adalah 58.52%. Kombinasi parameter yang digunakan untuk mencapai hasil tersebut adalah ukuran sel  $2 \times 2$  piksel, jumlah *bin* sebanyak 4 sehingga besar setiap *bin* adalah 45 derajat, kemudian nilai *sigma* yang digunakan untuk metode *SVM*

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

adalah 0.01. Dengan citra karakter inputan berukuran  $32 \times 32$  piksel. Maka panjang vektor fitur dari *HOG descriptor* yang dihasilkan adalah 3600 fitur.

Kolom di bagian kiri menunjukkan kombinasi parameter yang digunakan pada saat pengujian. Kolom CRR merupakan akronim dari *Character Recognition Rate* yang memiliki rumus jumlah karakter yang dikenali dibagi dengan keseluruhan karakter yang terdeteksi. Dari 143 karakter yang terdeteksi, sebanyak 88 di antaranya dapat diklasifikasikan dengan baik. Kolom OVR pada bagian kanan menunjukkan performa keseluruhan yang memiliki rumus jumlah plat nomor yang terdeteksi dan dikenali dengan benar dibagi dengan keseluruhan jumlah plat nomor yang ada. Dari 21 plat nomor yang terdeteksi, hanya 3 plat nomor yang dapat dikenali dengan baik.

Tabel 4.7 merupakan tabel yang menunjukkan hasil klasifikasi karakter dengan parameter HOG (*CellSize* dan *NumBins*) masing-masing 2 dan 4, dan nilai *sigma* untuk metode SVM 0.01.

**Tabel 4.7** Hasil klasifikasi karakter dengan parameter *CellSize* = 2, *NumBins* = 4, dan *Sigma* = 0.01

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
1	0	2	0	100.00%
2	1	15	7	68.18%
3	2	6	3	66.67%
4	3	2	6	25.00%
5	4	3	5	37.50%
6	5	2	2	50.00%
7	6	1	3	25.00%
8	7	6	7	46.15%
9	8	1	2	33.33%
10	9	2	4	33.33%
11	A	0	0	-
12	B	1	3	25.00%
13	C	1	0	100.00%
14	D	20	0	100.00%
15	E	1	0	100.00%
16	F	0	0	-
17	G	1	0	100.00%
18	H	1	0	100.00%
19	I	1	2	33.33%

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.7** Hasil klasifikasi karakter dengan parameter CellSize = 2, NumBins = 4, dan Sigma = 0.01

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
20	J	2	1	66.67%
21	K	2	0	100.00%
22	L	4	0	100.00%
23	M	1	0	100.00%
24	N	0	0	-
25	O	1	0	100.00%
26	P	1	3	25.00%
27	Q	2	0	100.00%
28	R	1	1	50.00%
29	S	1	1	50.00%
30	T	1	0	100.00%
31	U	1	0	100.00%
32	V	1	0	100.00%
33	W	2	5	28.57%
34	X	0	0	-
35	Y	1	0	100.00%
36	Z	1	0	100.00%

Dengan akurasi pengenalan karakter (*Character Recognition Rate*) sebesar 61.53%, dapat dilihat pada tabel 4.7 bahwa dari 36 karakter yang ada, yang dapat diprediksi dengan benar 100% adalah sebanyak 16 karakter, terdapat juga beberapa karakter yang memiliki akurasi pengenalan yang rendah, diantaranya adalah angka 3, angka 4, angka 6, angka 7, angka 8, angka 9, huruf B, huruf I, huruf P, dan huruf W. Dari hasil akurasi klasifikasi di atas, dapat disimpulkan bahwa penggunaan ukuran sel  $2 \times 2$  piksel kurang tepat untuk digunakan dalam proses ekstraksi fitur HOG dalam sistem pengenalan karakter ini.

##### 4.3.1.2 Pengujian dengan Ukuran Sel 4

Pada bagian ini, pengujian akan dilakukan dengan menggunakan ukuran sel berukuran  $4 \times 4$  piksel dan ukuran blok  $2 \times 2$  sel ( $8 \times 8$  piksel). Jumlah bin yang akan digunakan adalah 4, 6, 9, dan 18. Sedangkan untuk nilai sigma pada metode SVM yang akan digunakan adalah 0.01, 0.1, dan 1. Berikut adalah hasil pengujian untuk setiap kombinasi parameter tersebut:

#### IV. IMPLEMENTASI DAN PENGUJIAN

**Tabel 4.8** Hasil Pengujian dengan ukuran sel  $4 \times 4$  piksel

Parameter			CRR	OVR
CellSize	NumBins	Sigma		
4	4	0.01	88.11%	38.09%
4	4	0.1	50.34%	0%
4	4	1	27.97%	0%
4	6	0.01	86.71%	42.85%
4	6	0.1	44.05%	0%
4	6	1	26.57%	0%
4	9	0.01	90.20%	52.38%
4	9	0.1	44.05%	0%
4	9	1	25.87%	0%
4	18	0.01	87.41%	47.61%
4	18	0.1	44.05%	0%
4	18	1	25.87%	0%

Berdasarkan tabel di atas, dapat disimpulkan bahwa akurasi pengenalan karakter maksimal yang didapatkan apabila menggunakan ukuran sel  $4 \times 4$  piksel adalah 90.20%. Kombinasi parameter yang digunakan untuk mencapai hasil tersebut adalah ukuran sel  $4 \times 4$  piksel, jumlah *bin* sebanyak 9 sehingga besar setiap *bin* adalah 20 derajat, kemudian nilai *sigma* yang digunakan untuk metode *SVM* adalah 0.01. Dengan citra karakter inputan berukuran  $32 \times 32$  piksel. Maka panjang vektor fitur dari *HOG descriptor* yang dihasilkan adalah 1764 fitur. Jika dibandingkan dengan pengujian sebelumnya, jumlah fitur yang lebih sedikit justru mampu mendapatkan akurasi pengenalan karakter yang lebih baik.

Sama seperti bagian sebelumnya, kolom di bagian kiri menunjukkan kombinasi parameter yang digunakan pada saat pengujian. Dari hasil pada kolom CRR, dari 143 karakter yang terdeteksi, sebanyak 129 di antaranya dapat diklasifikasikan dengan baik. Dari hasil pada kolom OVR menunjukkan, dari 21 plat nomor yang terdeteksi, 11 plat nomor dapat dikenali dengan baik, hal ini merupakan peningkatan apabila dibandingkan dengan hasil pengujian sebelumnya, namun masih cukup banyak plat yang tidak dapat dikenali dengan baik.

Tabel 4.9 merupakan tabel yang menunjukkan hasil klasifikasi karakter dengan parameter HOG (*CellSize* dan *NumBins*) masing-masing 4 dan 9, dan nilai *sigma* untuk metode *SVM* 0.01.

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.9** Hasil klasifikasi karakter dengan parameter CellSize = 4, NumBins = 9, dan Sigma = 0.01

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
1	0	0	2	0.00%
2	1	18	4	81.82%
3	2	7	2	77.78%
4	3	8	0	100.00%
5	4	8	0	100.00%
6	5	4	0	100.00%
7	6	4	0	100.00%
8	7	13	0	100.00%
9	8	3	0	100.00%
10	9	6	0	100.00%
11	A	0	0	-
12	B	4	0	100.00%
13	C	1	0	100.00%
14	D	19	1	95.00%
15	E	1	0	100.00%
16	F	0	0	-
17	G	1	0	100.00%
18	H	1	0	100.00%
19	I	3	0	100.00%
20	J	2	1	66.67%
21	K	2	0	100.00%
22	L	4	0	100.00%
23	M	1	0	100.00%
24	N	0	0	-
25	O	1	0	100.00%
26	P	4	0	100.00%
27	Q	0	2	0.00%
28	R	2	0	100.00%
29	S	2	0	100.00%
30	T	1	0	100.00%
31	U	0	1	0.00%
32	V	1	0	100.00%
33	W	6	1	85.71%
34	X	0	0	-

#### IV. IMPLEMENTASI DAN PENGUJIAN

**Tabel 4.9** Hasil klasifikasi karakter dengan parameter CellSize = 4, NumBins = 9, dan Sigma = 0.01

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
35	Y	1	0	100.00%
36	Z	1	0	100.00%

Dengan akurasi pengenalan karakter (*Character Recognition Rate*) sebesar 90.20%, dapat dilihat pada tabel 4.9 bahwa dari 36 karakter yang ada, yang dapat diprediksi dengan benar 100% adalah sebanyak 24 karakter, terdapat juga beberapa karakter yang memiliki akurasi pengenalan yang rendah, diantaranya adalah angka 0, huruf Q, dan huruf U. Dari hasil akurasi klasifikasi di atas, dapat disimpulkan bahwa penggunaan ukuran sel  $4 \times 4$  piksel sudah dapat meningkatkan akurasi pengenalan karakter namun masih belum optimal.

##### 4.3.1.3 Pengujian dengan Ukuran Sel 8

Pada bagian ini, pengujian akan dilakukan dengan menggunakan ukuran sel berukuran  $8 \times 8$  piksel dan ukuran blok  $2 \times 2$  sel ( $16 \times 16$  piksel). Jumlah bin yang akan digunakan adalah 4, 6, 9, dan 18. Sedangkan untuk nilai sigma pada metode SVM yang akan digunakan adalah 0.01, 0.1, dan 1. Berikut adalah hasil pengujian untuk setiap kombinasi parameter tersebut:

**Tabel 4.10** Hasil Pengujian dengan ukuran sel  $8 \times 8$  piksel

Parameter			CRR	OVR
CellSize	NumBins	Sigma		
8	4	0.01	17.48%	0%
8	4	0.1	94.40%	71.42%
8	4	1	48.95%	0%
8	6	0.01	23.07%	0%
8	6	0.1	94.40%	71.42%
8	6	1	46.15%	0%
8	9	0.01	29.37%	0%
8	9	0.1	94.40%	71.42%
8	9	1	41.95%	0%
8	18	0.01	23.77%	0%
8	18	0.1	95.80%	80.95%
8	18	1	43.35%	0%

#### IV. IMPLEMENTASI DAN PENGUJIAN

Berdasarkan tabel di atas, dapat disimpulkan bahwa akurasi pengenalan karakter maksimal yang didapatkan apabila menggunakan ukuran sel  $8 \times 8$  piksel adalah 95.80%. Kombinasi parameter yang digunakan untuk mencapai hasil tersebut adalah ukuran sel  $8 \times 8$  piksel, jumlah *bin* sebanyak 18 sehingga besar setiap *bin* adalah 10 derajat, kemudian nilai *sigma* yang digunakan untuk metode *SVM* adalah 0.1. Dengan citra karakter inputan berukuran  $32 \times 32$  piksel. Maka panjang vektor fitur dari *HOG descriptor* yang dihasilkan adalah 648 fitur. Sama seperti pengujian sebelumnya, jika dibandingkan dengan pengujian sebelumnya, jumlah fitur yang lebih sedikit justru mampu mendapatkan akurasi pengenalan karakter yang lebih baik.

Sama seperti bagian sebelumnya, kolom di bagian kiri menunjukkan kombinasi parameter yang digunakan pada saat pengujian. Dari hasil pada kolom CRR, dari 143 karakter yang terdeteksi, sebanyak 137 di antaranya dapat diklasifikasikan dengan baik. Dari hasil pada kolom OVR menunjukkan, dari 21 plat nomor yang terdeteksi, 17 plat nomor dapat dikenali dengan baik, hal ini merupakan peningkatan apabila dibandingkan dengan hasil pengujian sebelumnya.

Tabel 4.11 merupakan tabel yang menunjukkan hasil klasifikasi karakter dengan parameter HOG (*CellSize* dan *NumBins*) masing-masing 8 dan 18, dan nilai *sigma* untuk metode *SVM* 0.1.

**Tabel 4.11** Hasil klasifikasi karakter dengan parameter *CellSize* = 8, *NumBins* = 18, dan *Sigma* = 0.1

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
1	0	2	0	100.00%
2	1	21	1	95.45%
3	2	7	2	77.78%
4	3	8	0	100.00%
5	4	8	0	100.00%
6	5	4	0	100.00%
7	6	4	0	100.00%
8	7	13	0	100.00%
9	8	3	0	100.00%
10	9	6	0	100.00%
11	A	0	0	-
12	B	4	0	100.00%
13	C	1	0	100.00%

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.11** Hasil klasifikasi karakter dengan parameter CellSize = 8, NumBins = 18, dan Sigma = 0.1

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
14	D	19	1	95.00%
15	E	1	0	100.00%
16	F	0	0	-
17	G	1	0	100.00%
18	H	1	0	100.00%
19	I	3	0	100.00%
20	J	3	0	100.00%
21	K	2	0	100.00%
22	L	4	0	100.00%
23	M	1	0	100.00%
24	N	0	0	-
25	O	1	0	100.00%
26	P	4	0	100.00%
27	Q	0	2	0.00%
28	R	2	0	100.00%
29	S	2	0	100.00%
30	T	1	0	100.00%
31	U	1	0	100.00%
32	V	1	0	100.00%
33	W	7	0	100.00%
34	X	0	0	-
35	Y	1	0	100.00%
36	Z	1	0	100.00%

Dengan akurasi pengenalan karakter (*Character Recognition Rate*) sebesar 95.80%, dapat dilihat pada tabel 4.11 bahwa dari 36 karakter yang ada, yang dapat diprediksi dengan benar 100% adalah sebanyak 29 karakter, dari karakter yang tersisa, hanya satu karakter yang memiliki akurasi rendah, yaitu huruf Q yang mana dari 2 karakter yang terdapat di data *testing*, tidak ada yang dapat diklasifikasikan dengan benar. Dari hasil pengujian ini dapat disimpulkan bahwa penggunaan ukuran sel  $8 \times 8$  piksel sudah dapat menghasilkan akurasi pengenalan karakter yang baik.



#### 4.3.1.4 Pengujian dengan Ukuran Sel 16

Pada bagian ini, pengujian akan dilakukan dengan menggunakan ukuran sel berukuran  $16 \times 16$  piksel dan ukuran blok  $2 \times 2$  sel ( $32 \times 32$  piksel). Jumlah bin yang akan digunakan adalah 4, 6, 9, dan 18. Sedangkan untuk nilai sigma pada metode *SVM* yang akan digunakan adalah 0.01, 0.1, dan 1. Berikut adalah hasil pengujian untuk setiap kombinasi parameter tersebut:

**Tabel 4.12** Hasil Pengujian dengan ukuran sel  $16 \times 16$  piksel

Parameter			CRR	OVR
CellSize	NumBins	Sigma		
16	4	0.01	13.98%	0%
16	4	0.1	20.27%	0%
16	4	1	83.91%	23.80%
16	6	0.01	13.98%	0%
16	6	0.1	25.17%	0%
16	6	1	83.21%	19.04%
16	9	0.01	13.98%	0%
16	9	0.1	30.76%	0%
16	9	1	86.71%	38.09%
16	18	0.01	13.98%	0%
16	18	0.1	25.87%	0%
16	18	1	86.01%	33.33%

Berdasarkan tabel di atas, dapat disimpulkan bahwa akurasi pengenalan karakter maksimal yang didapatkan apabila menggunakan ukuran sel  $16 \times 16$  piksel adalah 86.71%. Kombinasi parameter yang digunakan untuk mencapai hasil tersebut adalah ukuran sel  $16 \times 16$  piksel, jumlah *bin* sebanyak 9 sehingga besar setiap *bin* adalah 20 derajat, kemudian nilai *sigma* yang digunakan untuk metode *SVM* adalah 1. Dengan citra karakter inputan berukuran  $32 \times 32$  piksel. Maka panjang vektor fitur dari *HOG descriptor* yang dihasilkan adalah 9 fitur. Berbeda dengan pengujian sebelumnya, kali ini jumlah fitur yang terlalu sedikit justru akan mengurangi akurasi dari proses pengenalan karakter yang sebelumnya sudah mencapai 95.80%, dari keseluruhan pengujian yang sudah dilakukan terhadap jumlah sel, dapat disimpulkan bahwa ukuran sel yang terlampau besar ataupun terlampau kecil pada penggunaan metode *HOG* dapat mengurangi kualitas fitur yang dihasilkan sehingga akan berefek terhadap hasil klasifikasi.

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

Sama seperti bagian sebelumnya, kolom di bagian kiri menunjukkan kombinasi parameter yang digunakan pada saat pengujian. Dari hasil pada kolom CRR, dari 143 karakter yang terdeteksi, sebanyak 123 di antaranya dapat diklasifikasikan dengan baik. Dari hasil pada kolom OVR menunjukkan, dari 21 plat nomor yang terdeteksi, 7 plat nomor dapat dikenali dengan baik, hal ini merupakan dampak dari penurunan akurasi pengenalan karakter.

Tabel 4.13 merupakan tabel yang menunjukkan hasil klasifikasi karakter dengan parameter HOG (*CellSize* dan *NumBins*) masing-masing 16 dan 9, dan nilai *sigma* untuk metode SVM 1.

**Tabel 4.13** Hasil klasifikasi karakter dengan parameter *CellSize* = 16, *NumBins* = 9, dan *Sigma* = 1.0

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
1	0	2	0	100.00%
2	1	20	2	90.91%
3	2	6	3	66.67%
4	3	8	0	100.00%
5	4	8	0	100.00%
6	5	4	0	100.00%
7	6	4	0	100.00%
8	7	13	0	100.00%
9	8	3	0	100.00%
10	9	6	0	100.00%
11	A	0	0	-
12	B	3	1	75.00%
13	C	1	0	100.00%
14	D	19	1	95.00%
15	E	1	0	100.00%
16	F	0	0	-
17	G	1	0	100.00%
18	H	1	0	100.00%
19	I	0	3	0.00%
20	J	3	0	100.00%
21	K	2	0	100.00%
22	L	4	0	100.00%
23	M	1	0	100.00%
24	N	0	0	-

#### IV. IMPLEMENTASI DAN PENGUJIAN

---

**Tabel 4.13** Hasil klasifikasi karakter dengan parameter CellSize = 16, NumBins = 9, dan Sigma = 1.0

No	Karakter	Prediksi Benar	Prediksi Salah	Akurasi
25	O	1	0	100.00%
26	P	4	0	100.00%
27	Q	0	2	0.00%
28	R	2	0	100.00%
29	S	2	0	100.00%
30	T	1	0	100.00%
31	U	1	0	100.00%
32	V	1	0	100.00%
33	W	0	7	0.00%
34	X	0	0	-
35	Y	1	0	100.00%
36	Z	1	0	100.00%

Dengan akurasi pengenalan karakter (*Character Recognition Rate*) sebesar 86.71%, dapat dilihat pada tabel 4.13 bahwa dari 36 karakter yang ada, yang dapat diprediksi dengan benar 100% adalah sebanyak 25 karakter, terdapat juga karakter yang memiliki akurasi rendah, yaitu huruf I, huruf Q, dan huruf W. Apabila dibandingkan dengan hasil pengujian yang sebelumnya, dengan menggunakan ukuran sel 16 piksel justru malah mengurangi akurasi dari pengenalan karakter dan yang tadinya karakter tersebut sudah dapat dikenali dengan baik (huruf I dan huruf W) malah menjadi tidak bisa diklasifikasikan dengan benar sama sekali (akurasi 0% untuk kedua karakter tersebut). Dari pengujian ini dapat disimpulkan bahwa penggunaan ukuran sel  $16 \times 16$  piksel dapat menghasilkan akurasi pengenalan karakter yang baik namun belum optimal.

## BAB V

### PENUTUP

Bab ini berisi kesimpulan yang dilandasi oleh penelitian dan pengujian yang telah dilakukan, serta dilengkapi dengan saran yang dapat untuk perkembangan ke depan.

#### 5.1 Kesimpulan

Kesimpulan dari sistem pengenalan plat nomor kendaraan adalah:

1. Metode *HOG* memerlukan komposisi parameter yang tepat agar dapat menghasilkan fitur yang baik, ukuran sel yang terlalu kecil ataupun terlalu besar dapat mengurangi tingkat akurasi. Metode ini dapat menghasilkan akurasi yang baik walaupun citra latih karakternya berukuran kecil yaitu  $32 \times 32$  piksel, asalkan diimbangi dengan pemilihan komposisi parameter yang tepat. Hasil akurasi pengenalan karakter yang tertinggi yaitu sebesar 94.88% dicapai ketika menggunakan ukuran sel  $8 \times 8$  piksel, ukuran blok  $2 \times 2$  sel ( $16 \times 16$  piksel), jumlah bin sebanyak 18, dan nilai sigma sebesar 0.1.
2. Metode *Support Vector Machine* yang digunakan sebagai metode untuk klasifikasi karakter ternyata dapat menggunakan fitur dari metode *HOG* dan dapat menghasilkan akurasi yang baik dengan akurasi tertinggi sebesar 94.88% dengan nilai sigma yang digunakan adalah 0.1. Semakin besar ukuran sel yang digunakan pada metode *HOG*, maka nilai sigma untuk mendapatkan akurasi yang optimal untuk ukuran sel yang digunakan semakin besar.
3. Terdapat beberapa karakter yang dapat diklasifikasi dengan baik (rata-rata akurasi mencapai 100%) walaupun komposisi dari parameter *HOG* dan nilai sigma untuk metode *Support Vector Machine* yang digunakan beragam, karakter tersebut adalah huruf C, E, G, H, K, L, M, O, T, V, Y, dan huruf Z.
4. Terdapat juga karakter dengan akurasi klasifikasi yang rendah (rata-rata akurasi hanya 25%), huruf tersebut adalah huruf Q, huruf ini hanya dapat diklasifikasi dengan baik ketika menggunakan ukuran sel  $2 \times 2$  piksel, ukuran blok  $2 \times 2$  sel ( $4 \times 4$  piksel) dan nilai sigma untuk metode *Support Vector Machine* sebesar 0.01.

### 5.1.1 Saran

Saran untuk pengembangan sistem pengenalan plat nomor kendaraan adalah:

1. Metode *HOG* masih memerlukan metode tambahan untuk melakukan proses klasifikasi (misal SVM, K-NN, dan lain-lain), untuk metode *Support Vector Machine* sendiri memiliki kelemahan dalam hal sulitnya memilih parameter yang tepat untuk suatu permasalahan, parameter yang bagus untuk suatu kasus belum tentu bagus juga untuk kasus lainnya, untuk pengembangan lebih lanjut, pengenalan karakter dapat dicoba menggunakan metode *Deep Learning* yang dapat melakukan ekstraksi fitur dan klasifikasi dalam satu metode seperti *Convolutional Neural Network*.
2. Masih sering terjadi misklasifikasi pada karakter yang berbentuk mirip seperti misalnya huruf D dengan angka 0, huruf B dengan angka 8, huruf S dengan angka 5, huruf A dengan angka 4, dan beberapa karakter lainnya. Oleh karena itu diperlukan menambahkan metode klasifikasi atau metode ekstraksi fitur yang dapat mengambil fitur pasangan karakter yang mirip tersebut dengan lebih baik atau menggunakan metode *deep learning* seperti *Convolutional Neural Network* yang disebut memiliki kemampuan yang baik untuk melakukan ekstraksi fitur.

## DAFTAR REFERENSI

- [1] Tabrizi, S. S., Cavus, N. (2016). A hybrid KNN-SVM model for Iranian license plate recognition. *Procedia Computer Science*, 102, pp. 588-594.
- [2] Gou, C., Wang, K., Yu, Z., Xie, H. (2014, October). License plate recognition using MSER and HOG based on ELM. In *Proceedings of 2014 IEEE International Conference on Service Operations and Logistics, and Informatics* (pp. 217-221). IEEE.
- [3] Gou, C., Wang, K., Yao, Y., Li, Z. (2016). Vehicle license plate recognition based on extremal regions and restricted Boltzmann machines. *IEEE Transactions on Intelligent Transportation Systems*, 17(4), 1096-1107.
- [4] Rasheed, S., Naeem, A., Ishaq, O. (2012, October). Automated number plate recognition using hough lines and template matching. In *Proceedings of the World Congress on Engineering and Computer Science* (Vol. 1, pp. 24-26).
- [5] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4<sup>th</sup> ed. Pearson, 2018.
- [6] Shih, F.Y. (2010). *Image Processing And Pattern Recognition Fundamentals and Techniques*, Hoboken: John Wiley & Sons, Inc.
- [7] Computer Vision CITS4240: Lab 6, [Online]. Available: <http://teaching.csse.uwa.edu.au/units/CITS4240/Labs/Lab6/lab6.html> [Accessed: 16-Apr-2019].
- [8] Diagonals of a Rectangle, [Online]. Available: <https://www.mathopenref.com/rectanglediagonals.html> [Accessed: 13-May-2019].
- [9] Oechsle, Olly (2012). Finding Straight Lines with the Hough Transform, [Online]. Available: <http://vase.essex.ac.uk/software/HoughTransform/> [Accessed: 16-Apr-2019].
- [10] Ma, Y., & Guo, G. (Eds.). (2014). *Support Vector Machines Applications* (pp. 23-26). New York: Springer.

- [11] Nugroho, A., Wardhani, K.R.R. (2011). Aplikasi Sistem Pembaca Plat Nomor Mobil Menggunakan Pengolahan Citra dan Metode Learning Vector Quantization.
- [12] Peraturan Kapolri Nomor 5 tahun 2012 tentang Registrasi dan Identifikasi Kendaraan Bermotor, [Online]. Available: <http://kepri.polri.go.id/pid/wp-content/uploads/2019/01/PERATURAN-KAPOLRI-NOMOR-5-TAHUN-2012-TENTANG-REGISTRASI-DAN-IDENTIFIKASI-KENDARAAN-BERMOTOR.pdf> [Accessed: 22-Apr-2019]
- [13] Markham, Kevin (2014). Simple Guide to Confusion Matrix Terminology, [Online]. Available: <https://www.dataschool.io/simple-guide-to-confusion-matrix-terminology/> [Accessed: 22-Apr-2019].
- [14] H. K. Ragb and V. K. Asari, *Multi-feature Fusion and PCA Based Approach for Efficient Human Detection*, Applied Imagery Pattern Recognition Workshop (AIRP) IEEE, Washington, DC, USA, 2016, pp. 1-6.
- [15] Ashtari, A. H., Nordin, M. J., Fathy, M. (2014). An Iranian license plate recognition system based on color features. *IEEE transactions on intelligent transportation systems*, 15(4), 1690-1705.
- [16] R. Fisher, et all. (2003). Grayscale Images, [Online]. Available: <https://homepages.inf.ed.ac.uk/rbf/HIPR2/gryimage.htm> [Accessed: 26-Jun-2019]